

Prédiction des défaillances des PME avec TabTransformer et SHAP Analyse d'interprétabilité

Par

SHENGQI MA

UNIVERSITÉ PARIS DAUPHINE - PSL
MIAGE INFORMATIQUE DÉCISIONNELLE - APPRENTISSAGE
ENTREPRISE D'ACCUEIL : BPIFRANCE
TUTEUR ACADÉMIQUE : ELSA NEGRE
TUTEUR EN ENTREPRISE : DJIBA CISSE

AOÛT 2025

Abstract

La prédiction du risque de faillite des entreprises joue un rôle crucial dans les décisions de prêt des institutions financières. Pour l'évaluation du crédit des PME, des modèles efficaces peuvent aider les institutions financières à décider de l'octroi de prêts et à limiter leur exposition au risque. Cependant, la recherche actuelle sur la prédiction du risque de faillite des PME fait encore face à plusieurs défis, tels que : (1) une quantité de données généralement insuffisante, notamment en raison de la proportion très faible d'entreprises en faillite, et du fait que de nombreuses études utilisent uniquement des données d'une seule année, ce qui réduit encore davantage la taille des échantillons ; (2) avec l'application croissante de l'intelligence artificielle dans le domaine financier, l'interprétabilité des modèles devient de plus en plus importante. Les méthodes d'apprentissage traditionnelles sont souvent considérées comme des boîtes noires, difficiles à expliquer en termes de processus de décision et de logique sous-jacente aux résultats. Cela pose un problème de confiance dans des décisions critiques telles que l'octroi de crédits ou l'évaluation des risques. Ainsi, l'IA explicable devient un axe de recherche majeur, mais dans le domaine de la prédiction du risque de faillite, les études de ce type restent rares.

Face à ces problèmes, ce travail propose les contributions suivantes : (1) la collecte de données réelles et multi-sources sur les PME, afin de construire un nouveau jeu de données. Celui-ci contient des informations financières et non financières couvrant une période de dix ans pour 34 027 entreprises françaises, ce qui constitue une base solide pour nos analyses ; (2) sur la base de ce jeu de données, l'application d'un modèle de pointe pour les données tabulaires, TabTransformer. Cette approche comble l'écart de performance entre les modèles d'arbres de décision et les perceptrons multicouches, tout en surmontant la limite des modèles d'arbres qui ne sont pas adaptés à l'apprentissage continu sur des flux de données. En termes de performance, TabTransformer atteint des résultats comparables aux modèles les plus avancés de l'état de l'art. (3) Grâce à l'application de la méthode SHAP, les modèles traditionnellement considérés comme des boîtes noires sont transformés en systèmes plus transparents et explicables. Cela renforce leur opérabilité et leur compréhensibilité, et accroît leur fiabilité pour les institutions financières dans l'évaluation du crédit et la gestion des risques.

Table des matières

Abstract	i
1 Introduction	1
1.1 Contexte économique instable	1
1.2 Cas de Bpifrance	2
1.3 Problématique, Objectifs et Hypothèses	3
2 Revue de littérature	5
2.1 Cibles alternatives pour la prédiction de la faillite	6
2.2 L'identification des variables explicatives dans la prédiction des défaillances	8
2.2.1 Les variables financières	8
2.2.2 Les variables non financières	9
2.3 Le déséquilibre des classes	10
2.4 Models	11
2.4.1 Le modèle Z-score	11
2.4.2 Le modèle logit	12
2.4.3 Le support vector machine (SVM)	13
2.4.4 XGBoost	14
2.4.5 Random Forest	15
2.5 Comparaison des approches	16
3 Méthodologie	18
3.1 Données d'entraînement	18
3.1.1 Données d'entraînement	19
3.1.2 Prétraitement et qualité des données	26
3.1.3 Traitement des données	30

3.2	Configuration expérimentale	36
3.2.1	Méthodes de modélisation	36
3.2.2	Métrique d'évaluation	39
3.2.3	Environnement expérimental	41
3.2.4	Principaux hyperparamètres considérés	42
3.3	Résultats	44
3.3.1	Analyse des résultats expérimentaux	44
3.3.2	Analyse univariée	45
3.3.3	Analyse interprétative avec SHAP	46
3.3.4	Comparaison entre l'AUC univarié et l'importance SHAP	51
4	Conclusion	54
4.1	Conditions d'application du modèle proposé	54
4.2	Perspectives d'amélioration	55
4.3	Contributions et enseignements principaux	55
4.4	Limites et recommandations pour de futures recherches	56
4.5	Conclusion générale	57

Chapter 1

Introduction

1.1 Contexte économique instable

Une crise majeure s'est produite en 2019 en raison de l'épidémie de COVID-19, qui a eu un impact extrêmement grave sur l'économie mondiale. Par exemple, le PIB de la France a chuté de près de 8 % en 2020, soit la plus forte baisse depuis la Seconde Guerre mondiale. Les activités économiques normales étant affectées par les mesures d'isolement épidémique, la demande dans des secteurs tels que les transports, l'hôtellerie, la culture et la restauration a fortement diminué. Cela a conduit le gouvernement à introduire un certain nombre de mesures d'aide, telles que des mécanismes de chômage partiel, des reports d'impôts et de frais et des prêts garantis par l'État. Cependant, tout en évitant des faillites d'entreprises à grande échelle, ces aides ont inévitablement déclenché le phénomène d'hibernation économique. Ce phénomène masque la véritable situation financière d'un grand nombre d'entreprises, ce qui pousse certaines d'entre elles, initialement au bord de la faillite, à poursuivre leurs activités en s'appuyant sur une aide financière, mais elles n'ont pas la capacité de se développer durablement à long terme. Ainsi, lorsque les différentes aides prendront progressivement fin, ces entreprises seront confrontées à des problèmes tels que des tensions de trésorerie, un endettement excessif et un manque de perspectives de reprise.

Dans le même temps, de nombreux facteurs imprévisibles ont eu des répercussions multiformes sur le processus de reprise économique. Par exemple, l'escalade de la guerre en Ukraine en 2022 a fortement fait grimper les prix de l'énergie et a rendu la production plus coûteuse. La décision de la Banque centrale européenne d'augmenter ses taux

d'intérêt en est un autre exemple. Bien que cette mesure ait initialement été conçue pour freiner l'inflation, elle a rendu plus difficile pour les entreprises de lever des fonds. En 2025, une forte baisse du marché boursier américain a de nouveau suscité des inquiétudes quant à une récession mondiale.

Les entreprises doivent donc réfléchir à la manière de gérer les aléas d'un marché en constante évolution. De nombreuses menaces, telles que la baisse des commandes, la hausse des coûts et la réduction de l'accès au crédit, compliquent l'expansion du secteur financier. De ce fait, anticiper les faillites d'entreprises est plus crucial que jamais. Dans ce contexte, la nécessité de prédire les faillites d'entreprises est devenue plus urgente que jamais. Cependant, il n'existe toujours pas d'outil de prévision de faillite d'entreprise stable et mature sur le marché. Bien qu'il existe de nombreux prestataires de services et fournisseurs de solutions techniques, les institutions financières et les entreprises associées recherchent toujours des solutions fiables dotées de capacités prédictives plus efficaces et plus puissantes pour éviter d'éventuels risques financiers.

1.2 Cas de Bpifrance

Bpifrance, nom complet, est Banque Publique d'Investissement Française. La banque est détenue conjointement par l'État français et la Caisse des Dépôts. Depuis sa création, la mission principale de l'agence est d'accompagner le développement, la transformation et la compétitivité des entreprises françaises. Les interventions de Bpifrance prennent des formes variées, allant des prêts à court et long terme, aux garanties de prêts bancaires, en passant par la participation en fonds propres au financement des entreprises, couvrant un large éventail de secteurs, dont l'export, l'innovation ou encore la transition écologique. Les petites et moyennes entreprises (PME) sont ses principales cibles de services. Dans cet article, PME fait référence aux petites et moyennes entreprises.

Bpifrance a joué un rôle clé dans plusieurs crises ces dernières années. Après les attentats terroristes de 2015, les secteurs du tourisme et de la restauration ont été durement touchés et Bpifrance est rapidement intervenu en soutien. Lors de l'apparition de la pandémie de COVID-19 en 2020, l'agence a lancé conjointement avec l'État le mécanisme de Prêt Garanti par l'État (PGE) pour aider à injecter plus de 130 milliards d'euros de liquidités dans des centaines de milliers d'entreprises. Plus récemment, après que la guerre en Ukraine a provoqué une flambée des prix de l'énergie, Bpifrance a lancé un produit de prêt spécial pour aider les entreprises à ajuster leur structure de

consommation énergétique.

Comme mentionné précédemment, en tant qu’institution financière, BpiFrance est également confrontée à des risques induits par les changements de l’environnement extérieur. Malgré les différents mécanismes d’urgence, une question essentielle demeure toujours devant BpiFrance : comment identifier à temps les entreprises à risque avant qu’elles ne fassent faillite ? Il ne s’agit pas seulement d’une question de gestion des risques, mais aussi d’une manifestation importante de la responsabilité des entreprises dans l’utilisation des fonds publics. Fournir des fonds à une entreprise déjà en grande difficulté signifie une double perte : à la fois un risque financier et les conséquences d’une mise en œuvre ratée des politiques publiques. L’exemple de BpiFrance montre que construire des outils fiables pour prédire le risque potentiel d’insolvabilité des clients est une priorité opérationnelle urgente pour les entreprises du secteur.

1.3 Problématique, Objectifs et Hypothèses

Problématique.

Dans la prédiction de la faillite des petites et moyennes entreprises (PME), comment, dans des conditions de rareté des données et de forte déséquilibre de classes, construire un modèle adapté aux flux de données, doté d’une performance prédictive élevée et d’une bonne explicabilité ?

Objectifs.

Sur la base de la problématique ci-dessus, ce mémoire vise à :

1. Construire un nouveau jeu de données comprenant 34 027 entreprises françaises, couvrant dix ans d’informations financières et non financières, afin de fournir une base d’information plus solide pour la prédiction de la faillite ;
2. Introduire le modèle TabTransformer et le comparer aux modèles statistiques traditionnels (Logit), ainsi qu’aux modèles à base d’arbres (XGBoost, Forêt Aléatoire), afin d’évaluer sa performance et ses avantages dans le traitement des données tabulaires ;
3. Exploiter des méthodes d’explicabilité comme SHAP pour analyser l’importance des variables clés et leurs mécanismes d’action, et explorer la valeur potentielle des

sorties du modèle dans le processus de décision bancaire.

Hypothèses.

- H1** Le modèle TabTransformer présente une performance comparable aux modèles les plus avancés dans la prédiction de la faillite des PME.
- H2** Des études antérieures ont montré que les méthodes de rééchantillonnage (telles que SMOTE ou SMOTE-ENN) permettent d'améliorer le déséquilibre des classes et de réduire significativement les erreurs de type II (Aljawazneh et al., 2021). Ainsi, nous posons l'hypothèse que dans notre jeu de données, l'application de telles méthodes réduira le taux d'erreurs de type II, mais au prix d'une éventuelle diminution de la précision (Precision).
- H3** Bien que les informations non financières puissent avoir un impact positif sur la performance du modèle, les informations financières restent les indicateurs clés pour la prédiction de la faillite des entreprises.

Chapter 2

Revue de littérature

Au cours des 20 dernières années, avec le développement rapide de la puissance de calcul et des modèles d'apprentissage automatique, de plus en plus de publications ont appliqué le machine learning à la prédiction de la faillite d'entreprise. De plus en plus de travaux montrent que de nombreux modèles d'apprentissage automatique ont obtenu de très bons résultats dans ce domaine.

La majorité des recherches visent à comparer les modèles traditionnels (les modèles logit et probit) avec les modèles de machine learning. Certains auteurs (Zhang et al. 2010, Khandani et al. 2010) soulignent que les technologies d'apprentissage automatique, en particulier les forêts aléatoires (random forests) et les réseaux de neurones, présentent des avantages notables en termes de précision et de capacité à capter des relations complexes entre les variables. Jones (2023), après avoir comparé plusieurs modèles statistiques traditionnels, des modèles de machine learning, le NLP et l'apprentissage profond, a constaté que les modèles de machine learning (comme GBM, Random Forest, Deep Learning) obtenaient les meilleures performances, avec un pouvoir prédictif élevé et une grande robustesse. Ces modèles sont également plus adaptés au traitement de grandes quantités de données que les méthodes traditionnelles.

Mais certaines études ont aussi révélé que les modèles statistiques traditionnels restent très performants dans des contextes spécifiques, voire aussi efficaces que les modèles de machine learning. En plus, comparés au manque d'interprétabilité des modèles de machine learning, les modèles classiques sont plus explicables. (Fantazzini et Figini, 2009 ; Altman et al., 2017). C'est pourquoi, dans de nombreux secteurs financiers, quand la taille de l'échantillon est réduite ou que les données contiennent beaucoup de bruit, les

méthodes traditionnelles restent la norme.

Ces résultats divergents peuvent s’expliquer par plusieurs facteurs : la qualité et la taille des jeux de données utilisés, le type de variables explicatives choisies (financières ou non financières), ainsi que le contexte économique ou sectoriel étudié. Ainsi, il est particulièrement important d’analyser dans quelles conditions précises les méthodes de machine learning surpassent réellement les modèles traditionnels.

Ce travail de synthèse adopte précisément ce point de vue pour étudier les deux approches. Il s’agira de comparer de manière empirique l’efficacité de différents modèles dans la prédiction de la faillite des PME françaises. Enfin, une réflexion sera menée sur la base de la robustesse et de l’interprétabilité de ces modèles.

Selon la recommandation de Linnenluecke et al. (2020), ce mémoire adopte une structure thématique plutôt qu’une structure centrée sur les auteurs. Cette approche permet de regrouper les recherches en fonction de leurs apports conceptuels et méthodologiques, afin de mieux mettre en évidence les tendances, contradictions et lacunes dans la littérature existante. Autrement dit, il ne s’agit pas de simplement énumérer les contributions d’auteurs individuels, mais de structurer la revue autour de quatre grands thèmes clés dans la prédiction de la faillite d’entreprise :

1. Les cibles alternatives de prédiction de la faillite
2. L’identification des variables explicatives pertinentes, au-delà des seuls ratios financiers : variables de marché, indicateurs de gestion du résultat, opinions de continuité d’exploitation (GCOs), caractéristiques de gouvernance, etc.
3. La problématique du déséquilibre des classes et les méthodes de correction
4. Le développement et l’application des modèles statistiques traditionnels et des techniques d’apprentissage automatique

2.1 Cibles alternatives pour la prédiction de la faillite

La définition de la faillite ou de l’échec d’entreprise varie d’un pays à l’autre. Dans les recherches académiques, différentes méthodes donnent des interprétations différentes à

cette notion. Cela nous offre plusieurs choix ou alternatives lorsqu'il s'agit de définir l'objectif de prédiction de l'échec d'une entreprise. Le choix de cette cible est donc très important.

Du point de vue juridique, la faillite correspond généralement à une procédure formelle, comme la liquidation judiciaire, le redressement judiciaire, ou encore une demande de protection fondée sur une loi spécifique (comme le Chapitre XI aux États-Unis). Ce type de définition est souvent utilisé par les agences de notation (comme Dun & Bradstreet), les autorités fiscales ou judiciaires, car il est très objectif. C'est pourquoi dans les bases de données nationales françaises, cette définition est utilisée comme référence.

À l'inverse, certaines définitions de l'échec d'entreprise sont moins objectives. Elles sont plus larges, mais sont également couramment utilisées dans de nombreuses études. Par exemple, l'incapacité à atteindre les objectifs stratégiques fixés par la direction, des pertes durables, ou des doutes récurrents exprimés par les commissaires aux comptes sur la capacité de l'entreprise à poursuivre son activité. Cette approche est particulièrement pertinente dans l'étude des PME. En effet, dans la réalité, même si une entreprise est en grande difficulté financière, elle ne passe pas nécessairement par une procédure judiciaire (Argenti, 1976).

Dans la pratique, la plupart des modèles prédictifs prennent encore comme cible principale l'incapacité à rembourser les dettes à échéance. En effet, la plupart des prévisions de faillite sont faites dans le but d'éviter les pertes liées aux défauts de paiement. Cela correspond à des situations de défaut ou de demande de protection juridique. Cependant, cette situation arrive souvent trop tard, quand la situation de l'entreprise est déjà irrémédiable. C'est pourquoi certains chercheurs suggèrent d'utiliser des cibles alternatives plus précoces et plus sensibles, comme la suspension du paiement des charges sociales, les retards prolongés de paiement aux fournisseurs, la perte de contrats commerciaux ou encore l'interruption de financement bancaire (Laitinen, 1991 ; Balcaen Ooghe, 2006).

De nombreuses études ont confirmé que les causes de l'échec d'entreprise sont très similaires. Plus de 90% des faillites sont dues à une mauvaise gestion (Argenti, 1976 ; Business Week, 1980 ; CPA Journal, 1993). La mauvaise gestion comprend des erreurs de stratégie, un manque de capacité d'exécution, ou une réponse trop lente aux évolutions de l'environnement. Il existe également des facteurs externes difficilement prévisibles, comme les chocs macroéconomiques ou les changements rapides de marché. Par exemple,

la crise économique de 2018, la crise du COVID-19 en 2020, et la crise énergétique récente. Ces crises mondiales ont accéléré la faillite de nombreuses entreprises déjà fragiles. Même des entreprises saines n'ont pas pu y résister. Pour qu'un modèle puisse s'adapter à ces cas, il est nécessaire d'intégrer certains indicateurs macroéconomiques dans l'analyse.

Enfin, on distingue deux grandes méthodes pour étudier l'échec d'entreprise : l'approche causale. Elle est souvent qualitative et vise à identifier les causes profondes : erreurs stratégiques, manque de financement ou gouvernance défaillante ; et l'approche symptomatique, qui cherche à détecter les signaux d'alerte mesurables, comme la dégradation des indicateurs financiers, la baisse du chiffre d'affaires ou la perte de clients clés. Cette deuxième approche est au cœur des systèmes de scoring et des modèles de prédiction automatique, en particulier ceux basés sur le machine learning.

2.2 L'identification des variables explicatives dans la prédiction des défaillances

Dans les recherches récentes sur la prédiction de la faillite d'entreprise, de plus en plus de publications soulignent le rôle important des variables non financières. L'introduction de ces variables permet d'avoir une vision plus globale de la situation de l'entreprise lors de l'analyse du risque de défaillance. Pour faire face aux crises mondiales imprévues, l'introduction des variables macroéconomiques est aussi indispensable. Cette partie sera divisée en trois catégories : les variables financières, les variables non financières, et les variables macroéconomiques externes.

2.2.1 Les variables financières

Les variables financières ont toujours constitué la base principale des modèles de prédiction de faillite. Ces variables incluent principalement des ratios issus des états financiers de l'entreprise, tels que la rentabilité $\frac{\text{Résultat net}}{\text{Chiffre d'affaires}}$, la liquidité $\frac{\text{Actifs courants}}{\text{Passifs à court terme}}$, la solvabilité $\frac{\text{Capitaux propres}}{\text{Total des passifs}}$, ainsi que le levier financier $\frac{\text{Dettes}}{\text{Capitaux propres}}$. Ces indicateurs sont largement utilisés dans les recherches anciennes comme récentes.

Dans la littérature des premiers modèles statistiques, le modèle Z-score classique proposé par Altman (1968) utilise l'analyse discriminante pour combiner cinq ratios financiers clés : $\frac{\text{Fonds de roulement}}{\text{Total de l'actif}}$, $\frac{\text{Bénéfices non distribués}}{\text{Total de l'actif}}$, $\frac{\text{EBIT}}{\text{Total de l'actif}}$, $\frac{\text{Valeur de marché}}{\text{Dettes}}$, et $\frac{\text{Chiffre d'affaires}}{\text{Total de l'actif}}$.

Le modèle logit de Ohlson (1980) inclut la taille de l'entreprise (log des actifs totaux), le ratio $\frac{\text{Dettes totales}}{\text{Actifs totaux}}$ (TLTA), $\frac{\text{Résultat net}}{\text{Actif}}$ (NITA), la variation des bénéfices (CHIN), et une variable binaire pour les pertes consécutives.

D'autres chercheurs, comme Beaver (1966), Zmijewski (1984) et Laitinen (1991), ont également confirmé la capacité prédictive élevée de ces indicateurs financiers classiques

Dans une étude plus récente utilisant des réseaux de neurones, Ilyes et Rim (2022) ont utilisé des variables comme $\frac{\text{Résultat net}}{\text{Actif total}}$, $\frac{\text{Impôt}}{\text{Valeur ajoutée}}$, et $\frac{\text{Investissement}}{\text{Valeur ajoutée}}$ comme variables principales dans la prédiction de la faillite des entreprises.

Nous constatons ainsi que, que ce soit dans les modèles statistiques classiques ou dans les modèles récents basés sur l'intelligence artificielle, les variables financières restent des indicateurs essentiels.

2.2.2 Les variables non financières

En raison des limites des données financières seules, de plus en plus de recherches se concentrent sur ce qu'on appelle les variables non financières. Ces variables incluent des indicateurs structurels, opérationnels ou comportementaux, qui enrichissent considérablement l'analyse du risque.

Parmi ces variables, on retrouve :

- **Les caractéristiques juridiques et démographiques** : âge, taille, forme juridique, localisation géographique
- **Les variables liées à la gouvernance d'entreprise** : présence d'un audit externe, rotation des dirigeants, concentration de l'actionnariat (Daily & Dalton, 1994 ; Platt & Platt, 2012)
- **Les opinions des auditeurs** sur la continuité d'exploitation, souvent considérées comme un signal d'alerte majeur (Geiger & Raghunandan, 2002)
- **Les indicateurs de gestion du résultat**, comme les accruals ou les manipulations comptables suspectées (Jones, 1991 ; Dechow et al., 1995)
- **Les comportements fiscaux et administratifs**, comme les retards de paiement de cotisations sociales, les litiges avec l'administration, ou encore les ruptures de contrats commerciaux.

Récemment, dans le domaine du machine learning, certaines études ont également exploré l'intégration de données non structurées ou issues de sources alternatives, telles que les textes d'articles, les données fiscales, ou encore les comportements des entreprises. Ces données permettent de détecter des signaux faibles que les états financiers traditionnels ne révèlent pas, rendant possible une détection plus précoce des crises à venir.

2.3 Le déséquilibre des classes

Dans la recherche sur la prédiction des faillites d'entreprises, il existe un problème très courant : le déséquilibre sévère des classes. En effet, les entreprises en faillite sont souvent minoritaires, et le nombre d'entreprises non défaillantes est toujours beaucoup plus élevé. La proportion d'entreprises en faillite oscille généralement entre 1 % et 6 % (Zieba, Tomczak & Tomczak, 2016 ; Brown & Mues, 2012). Ce déséquilibre nuit gravement à l'apprentissage des modèles de prédiction, car les modèles ont tendance à bien reconnaître la classe majoritaire (les entreprises saines), mais à ignorer la classe minoritaire, pourtant celle que l'on cherche à détecter. Si l'on utilise un modèle simple qui prédit que toutes les entreprises vont survivre, alors la précision globale sera peut-être élevée, car la majorité des entreprises sont effectivement saines. Mais un tel modèle n'a aucune valeur réelle dans la gestion du risque.

Ce problème statistique soulève également une question stratégique importante : faut-il minimiser les faux positifs ou les faux négatifs ? En évaluation des risques, on s'intéresse généralement à deux types d'erreurs : les faux positifs (faux avertissements, c'est-à-dire une entreprise est prédite en faillite mais ne l'est pas), et les faux négatifs (échec de détection, c'est-à-dire une entreprise réellement en difficulté n'est pas identifiée) (Brown & Mues, 2012 ; Khosravi, Rezaee & Shajari, 2021). Dans la plupart des contextes de gestion du crédit, le coût d'un faux négatif est beaucoup plus élevé que celui d'un faux positif. En effet, ne pas détecter une entreprise à haut risque peut entraîner des pertes financières importantes ; alors qu'un faux positif mène souvent seulement à un refus de crédit ou à une mauvaise allocation des ressources. Ainsi, le principal objectif en modélisation devient la maximisation du rappel (recall), c'est-à-dire la capacité à identifier un maximum de vraies faillites, même si cela réduit légèrement la précision globale. Cela signifie qu'il faut choisir des modèles plus sensibles à la classe minoritaire (les entreprises en difficulté).

Dans la littérature, les stratégies de correction du déséquilibre sont souvent regroupées

en deux grandes catégories : les méthodes au niveau des données et les méthodes au niveau des algorithmes. Au niveau des données, on peut réduire manuellement le nombre d'exemples dans la classe majoritaire (sous-échantillonnage), ou au contraire, dupliquer ou générer de nouveaux exemples pour la classe minoritaire (sur-échantillonnage). La méthode SMOTE (Synthetic Minority Oversampling Technique) est reconnue dans de nombreux travaux comme la plus efficace. Elle génère de nouvelles données synthétiques en interpolant entre des exemples existants de la classe minoritaire. Cette méthode est largement utilisée dans la prédiction de faillite car elle améliore fortement le rappel sans provoquer de sur-apprentissage excessif (Chawla et al., 2002 ; Zieba et al., 2016 ; Xie et al., 2021)

L'apprentissage sensible au coût (cost-sensitive learning) est aujourd'hui intégré dans de nombreux algorithmes, tels que les forêts aléatoires pondérées et les SVM pénalisés. Des recherches récentes (Brown & Mues, 2012 ; Zhou et al., 2021) suggèrent même d'utiliser des stratégies hybrides, combinant des méthodes comme SMOTE avec des algorithmes sensibles au coût, afin d'améliorer les performances tout en conservant une bonne capacité de généralisation

2.4 Models

2.4.1 Le modèle Z-score

Le modèle Z-score a été proposé par Altman en 1968, c'est l'un des modèles les plus classiques et les plus connus pour prédire la faillite des entreprises. Il est basé sur l'analyse discriminante linéaire. Le modèle Z-score combine cinq ratios financiers avec des poids pour former un score : fonds de roulement/total de l'actif, bénéfices non distribués/total de l'actif, résultat d'exploitation/total de l'actif, valeur du capital des actionnaires/total des dettes, chiffre d'affaires/total de l'actif. Quand cette technique a commencé à être utilisée, elle a très bien fonctionné pour prédire le risque de faillite de certaines entreprises industrielles cotées aux États-Unis, ce qui a conduit à de plus en plus de recherches basées sur ce modèle.

Le rapport d'Altman (1968) montre que le taux de mauvaise classification pour les entreprises en faillite est d'environ 5 %. Plus tard, Altman et McGough (1974) ont utilisé ce modèle avec les données des entreprises en faillite entre 1970 et 1973. Ils ont été déçus de constater que le taux de mauvaise classification est monté à 18 %, ce qui montre que

le modèle Z-score a une capacité de généralisation insuffisante, il est peut-être seulement applicable aux données de certaines années. Finalement, Altman (1977) a développé un nouveau modèle à partir du modèle d'origine, le modèle ZETA. Ce nouveau modèle a introduit plus de combinaisons de variables et des algorithmes plus avancés pour améliorer le modèle. Mais à la fin, il n'a pas présenté les résultats de ce nouveau modèle sur les données après 1974, ce qui ne nous permet pas de vérifier si ce modèle est applicable à d'autres années. Ohlson (1980) dit dans sa recherche que cette situation difficile montre que le modèle Z-score dépend de l'échantillon, ce qui signifie que ce modèle ne s'applique qu'aux données d'apprentissage et ne peut pas être généralisé à d'autres données.

Ces dernières années, avec l'importance croissante des facteurs non financiers dans l'analyse des risques d'entreprise, le modèle Z-score a du mal à s'adapter à cause de sa structure fixe, et il est aussi difficile d'y intégrer des variables hétérogènes venant de plusieurs sources, ce qui limite petit à petit son applicabilité dans l'environnement complexe d'aujourd'hui.

2.4.2 Le modèle logit

Par rapport à l'analyse discriminante linéaire (LDA) et au modèle probit, le principal avantage du modèle logit est sa forte interprétabilité, ses coefficients ont une signification économique plus claire, ses hypothèses statistiques sont plus souples et il ne nécessite pas que les données suivent une distribution normale. Les modèles probit et logit appartiennent à la famille des modèles de choix discrets, en supposant que, pour toute entreprise donnée, et selon un ensemble de facteurs de risque, sa faillite ou non peut être définie comme un problème de probabilité. (Ohlson, 1980)

Ohlson (1980) est l'un des premiers chercheurs à avoir utilisé la régression logistique (modèle logit) pour la prédiction de la faillite des entreprises. Dans l'étude d'Ohlson, il a utilisé un échantillon de données de la bourse de 1970 à 1976. Il a utilisé les données de 105 entreprises en faillite et de 2 058 entreprises non faillies. Dans ses résultats de recherche, certaines entreprises avaient des rapports financiers qui semblaient bons, mais elles étaient tout de même en faillite. Cela montre que, lorsqu'on utilise uniquement des variables financières pour prédire la faillite des entreprises, l'explication reste insuffisante. Par rapport au modèle Z-score d'Altman, l'interprétabilité est meilleure. Le modèle logit a une bonne stabilité.

Bernhardsen (2001) a ensuite proposé que l'on peut améliorer la capacité d'ajustement

du modèle logit grâce à des transformations non linéaires (comme Box-Cox ou la fonction logistique cumulative). Cette variante du modèle logit a obtenu une meilleure précision de prédiction dans des structures de données complexes.

Ces dernières années, de plus en plus de recherches ont commencé à souligner les limites structurelles du modèle logit. Par exemple, Gavurova et al. (2022) et Alam et al. (2020) ont découvert que, dans des ensembles de données très déséquilibrés (où les entreprises saines sont beaucoup plus nombreuses que les entreprises en faillite), le modèle logit sous-estime généralement la probabilité réelle de faillite, en particulier pour les petites et moyennes entreprises. Kanapickienė et al. (2023) ont aussi constaté que, lorsque la période de prévision dépasse trois ans, la précision du modèle logit diminue rapidement, principalement à cause de l'évolution du comportement financier des entreprises qui affecte la stabilité des coefficients du modèle.

Même s'il existe de nombreuses limites, la régression logistique reste un modèle qui demande peu de données, qui est très interprétable, et qui est relativement simple à calculer. Dans le secteur financier, la régression logistique reste une méthode largement utilisée, surtout dans les domaines où l'on a besoin d'une forte interprétabilité.

2.4.3 Le support vector machine (SVM)

Le support vector machine (SVM) est une technique d'apprentissage supervisé dans le domaine de l'intelligence artificielle. Depuis plusieurs années, il est largement utilisé dans différents problèmes de classification binaire, c'est pourquoi cet article l'utilise pour prédire la faillite des entreprises. Contrairement aux modèles linéaires comme la régression logistique, le SVM peut trouver un hyperplan optimal dans l'espace des caractéristiques pour séparer les entreprises en deux catégories : faillite et non-faillite. Même si les données ne sont pas linéairement séparables, le SVM peut utiliser une fonction noyau pour projeter les données dans un espace de dimension plus élevée, ce qui permet une classification efficace.

Le support vector machine a été utilisé pour la première fois en 2005 pour prédire la faillite des entreprises, c'est Shin, Lee et Kim (2005) qui l'ont proposé. Ils ont principalement comparé le SVM avec le réseau de neurones à rétropropagation traditionnel (BNP). Leur étude utilise des données fournies par le Korea Credit Guarantee Fund (Fonds coréen de garantie de crédit). Dans les données, il y a au total 2 320 entreprises manufacturières de taille moyenne, dont la moitié sont des entreprises en faillite et l'autre

moitié des entreprises non faillies. Il y a 1 160 entreprises en faillite et 1 160 entreprises non faillies. Après l'entraînement, ils ont constaté que, par rapport au BNP, le modèle SVM a une structure plus simple, une précision de prédiction plus élevée, une meilleure capacité de généralisation. Quand la taille du jeu d'entraînement est petite (moins de 200), les performances du BNP diminuent fortement, et parfois il n'arrive même pas à converger ; en comparaison, le SVM maintient une bonne performance de classification même avec un très petit ensemble d'entraînement.

Jones et ses collègues (2015 et 2017) ont inclus le SVM dans une étude de comparaison à grande échelle sur les modèles de prédiction de la faillite d'entreprise et les changements de notation de crédit, avec 16 classificateurs principaux. Le SVM a bien fonctionné dans l'ensemble, mais il n'est pas toujours meilleur que des méthodes d'ensemble comme les arbres de décision boosting ou les forêts aléatoires. Cependant, les auteurs ont précisé que, lorsque les données sont propres et que les variables sont bien standardisées, le SVM est une alternative très puissante et efficace.

Cependant, le SVM a aussi quelques défauts importants. D'abord, il a une faible interprétabilité, ce qui peut poser problème dans les cas où les décisions de crédit (comme l'approbation d'un prêt bancaire) doivent être expliquées et justifiées. Ensuite, le SVM est très sensible au réglage des paramètres du modèle (comme le paramètre de régularisation C et le type de noyau utilisé). Si les paramètres sont mal choisis, la performance prédictive peut être affectée, donc il faut un niveau technique élevé chez l'utilisateur. En plus, même si de nombreuses versions accélérées ont été développées au fil des années, le SVM a toujours un coût d'entraînement élevé quand on traite de grands ensembles de données.

En général, le SVM reste une technique de prédiction de faillite adaptée pour traiter des données complexes, avec beaucoup de dimensions ou des relations non linéaires. C'est pourquoi, dans les recherches récentes sur l'application de l'apprentissage automatique, il est souvent utilisé comme modèle de référence. À cause de son manque de transparence et de sa complexité d'utilisation, le SVM est moins populaire que les algorithmes d'ensemble plus interprétables comme XGBoost ou les forêts aléatoires, qui sont généralement préférés en pratique.

2.4.4 XGBoost

XGBoost est un algorithme de type Gradient Boosting. Ce type d'algorithme vient lui-même des algorithmes de Boosting (Chen & Guestrin, 2016). Les contributions du

Boosting au domaine du Machine Learning ont été décrites dans une thèse de 2006 (Suchier, 2006). La méthode standard du Boosting est : entraîner plusieurs “apprenants faibles” de manière continue, puis les combiner pour former un “apprenant fort”. À chaque itération, le modèle corrige les erreurs de la boucle précédente en réajustant les poids : les exemples mal classés voient leur poids augmenter de façon exponentielle, tandis que les exemples bien classés ont un poids réduit.

XGBoost continue à réduire l’erreur de généralisation même avec un grand nombre d’itérations, ce qui montre une bonne capacité de convergence. Cela le distingue des arbres de décision classiques, qui ont tendance à surapprendre : quand il y a trop d’itérations, l’erreur de généralisation augmente (Freund & Schapire, 1997 ; Schapire et al., 1997 ; Schapire & Singer, 1999).

Barboza et al. (2017) ont comparé plusieurs modèles dans la prédiction des faillites d’entreprise, comme le SVM, les forêts aléatoires, le Bagging, le Boosting. Ils ont finalement trouvé que XGBoost avait les meilleures performances globales.

2.4.5 Random Forest

La méthode Random Forest est une amélioration du système CART (Classification and Regression Trees, basé sur la partition binaire récursive) et des algorithmes d’arbres de décision de type bagging. Ces derniers souffrent souvent d’un problème de forte variance (c’est-à-dire que si l’on divise l’échantillon d’entraînement en deux moitiés aléatoires, les modèles générés peuvent être très différents), et leur précision de classification est plus faible

La méthode Random Forest fait partie de l’apprentissage ensembliste, dans la catégorie des méthodes Bagging (abréviation de Bootstrap Aggregation). L’apprentissage ensembliste comprend le boosting et le bagging, et la Random Forest appartient au bagging

La Random Forest conserve les avantages des méthodes CART et bagging, tout en améliorant les performances grâce à la dé-corrélation des structures d’arbre, et en utilisant un mécanisme de vote d’ensemble proche de celui du gradient boosting (approche d’ensemble ou de vote majoritaire)

L’idée intuitive est la suivante : dans le processus de bagging d’arbres de décision, si un prédictor très fort existe dans les données (et d’autres variables de force modérée),

la plupart des arbres choisiront ce prédicteur lors de leur première division. Ainsi, tous les arbres de bagging auront une structure très similaire, ce qui rendra leurs prédictions fortement corrélées. Or, faire la moyenne de prédictions très corrélées ne permet pas de réduire beaucoup l’erreur. Au contraire, faire la moyenne de prédictions non corrélées permet de mieux diminuer l’erreur totale

Les données liées aux faillites d’entreprises contiennent souvent des valeurs manquantes, des valeurs aberrantes ou des erreurs de codage, ce que l’on appelle des “données sales”. Comparé aux modèles paramétriques classiques (comme le Logit ou l’analyse discriminante), Random Forest ne nécessite pas d’hypothèse sur la distribution des variables, ni de tests de significativité, ni de transformation des variables. Elle permet de traiter les caractéristiques brutes plus naturellement, ce qui réduit les biais liés aux décisions subjectives des chercheurs

Plus important encore, Random Forest sélectionne et classe les variables selon leur performance prédictive, et non à travers des tests statistiques. Cela lui donne un avantage naturel contre les problèmes de “p-hacking” et de “data snooping”

2.5 Comparaison des approches

Dans la prédiction de la défaillance des PME, les approches diffèrent fortement selon plusieurs dimensions critiques : interprétabilité, performance prédictive, réglage des hyperparamètres, faisabilité de déploiement, choix des métriques et coût computationnel. Sur le plan de l’interprétabilité, la régression logistique reste la méthode la plus transparente : chaque coefficient traduit directement l’effet marginal d’une variable sur la probabilité de défaut, ce qui explique son usage historique en scoring de crédit (Chen et al., 2022) et sa persistance dans les pratiques contemporaines pour des raisons de conformité réglementaire . Les modèles d’arbres de décision, tels que XGBoost ou CatBoost, offrent une interprétabilité intermédiaire grâce aux importances de variables ou à des outils comme SHAP (Lundberg & Lee, 2017), mais ces explications relèvent surtout de corrélations statistiques et sont moins intuitives économiquement. Quant à TabTransformer, bien qu’il puisse être couplé à SHAP, l’interprétation des poids d’attention et des embeddings reste abstraite et difficile à valoriser auprès des régulateurs (Huang et al., 2020).

Du point de vue de la performance, les modèles d’arbres demeurent l’étalon industriel

sur les données tabulaires (Chen & Guestrin, 2016), tandis que TabTransformer montre un potentiel intéressant en termes de rappel et de réduction des faux négatifs, dimension cruciale dans le contexte bancaire (Huang et al., 2020). Toutefois, cette supériorité n'est pas systématique, et sa stabilité reste limitée sur des échantillons de taille moyenne (Somepalli et al., 2021). Concernant les hyperparamètres, la régression logistique ne requiert presque aucun réglage et garantit une grande stabilité, tandis que les modèles d'arbres, bien que sensibles à la profondeur ou au taux d'apprentissage, bénéficient d'une longue expérience empirique et d'outils robustes (Prokhorenkova et al., 2018). TabTransformer, en revanche, impose de choisir de nombreux paramètres (taille des embeddings, nombre de têtes, couches, régularisation), ce qui accroît la variance des résultats.

En matière de déploiement, la logistique et les arbres sont aisément intégrés dans les systèmes bancaires via des bibliothèques standards, alors que TabTransformer nécessite un environnement GPU, un suivi MLOps complexe et engendre des coûts de maintenance plus élevés (Huang et al., 2020). Sur le plan des métriques d'évaluation, la majorité des travaux se limite à l'AUC et au F1-score (Abedin et al., 2023), ce qui ne suffit pas à juger la pertinence pratique. Dans le contexte bancaire, il est crucial de prendre en compte le rappel, la calibration (Brier score, courbes de calibration) ainsi que la significativité statistique des écarts de performance (DeLong et al., 1988). Enfin, concernant le coût computationnel, la logistique reste la plus économe, les arbres offrent un compromis acceptable même à grande échelle, tandis que TabTransformer s'avère bien plus coûteux, ce qui limite son intérêt pratique si les gains marginaux de performance ne compensent pas ces surcoûts.

En résumé, TabTransformer représente une piste prometteuse pour améliorer le rappel et capter des interactions complexes, mais il demeure pénalisé par des problèmes d'interprétabilité, de stabilité, de déploiement et de coût. Dans l'état actuel, les modèles d'arbres apparaissent comme le meilleur compromis pour les institutions financières, tandis que la régression logistique conserve sa pertinence comme modèle de référence et outil explicatif.

Chapter 3

Méthodologie

Cette section présente les travaux expérimentaux réalisés sur un jeu de données réel, ainsi qu'un ensemble d'expériences complémentaires. Dans un premier temps, le processus de construction du jeu de données est décrit en détail, incluant la collecte des informations, la transformation au format long et les principales caractéristiques statistiques de l'échantillon. Deux méthodes sont ensuite exposées pour traiter le déséquilibre des classes. Par la suite, l'environnement expérimental est présenté, ainsi que les indicateurs utilisés pour l'évaluation des performances des modèles. Enfin, afin de mettre en évidence les avantages du modèle proposé sous différents angles, une série d'expériences complémentaires a été conçue : tests univariés, regroupement de nœuds, expériences d'ablation et analyses de sensibilité aux hyperparamètres. L'ensemble de ces expériences confirme la validité et la robustesse de l'approche.

3.1 Données d'entraînement

Ce chapitre présente les sources de données utilisées dans cette recherche, les méthodes de collecte, la composition des variables, les catégories de données, ainsi que l'idée et le processus de prétraitement des données. L'objectif de cette recherche est d'utiliser des méthodes comme l'apprentissage automatique et l'apprentissage profond pour prédire la faillite des entreprises. Cette recherche a non seulement choisi des ensembles de données représentatifs, couvrant des indicateurs financiers multidimensionnels comme base d'entrée du modèle, mais aussi des données non financières comme complément supplémentaire de dimension.

3.1.1 Données d'entraînement

3.1.1.1 Sources et description des données

Les données utilisées dans cette étude proviennent principalement de la base de données Orbis (fournie par Bureau van Dijk), qui couvre les entreprises du monde entier et contient des informations financières et non financières détaillées. Dans le cadre de cette recherche, nous avons sélectionné 16 000 observations d'entreprises non défaillantes sur les dix dernières années et 15 000 observations d'entreprises défaillantes sur les dix années précédant leur faillite. Les entreprises étudiées sont de type petites et moyennes entreprises (PME) situées en France. Les entreprises défaillantes comprennent différents statuts : en liquidation, en faillite, dissoutes (par fusion ou acquisition, par scission, par liquidation, par faillite). Les entreprises non défaillantes incluent également certaines en activité mais avec des irrégularités administratives ou ayant procédé à un remboursement anticipé.

Dès la phase de collecte, nous avons équilibré le nombre d'entreprises défaillantes et non défaillantes, évitant ainsi le problème du déséquilibre des classes dès la constitution de l'échantillon.

La base Orbis fournit des variables couvrant plusieurs dimensions : informations générales sur l'entreprise, classification sectorielle, états financiers, ratios comptables, structure de propriété, etc. Elle est particulièrement adaptée à la modélisation de la prédiction des faillites. Dans cette étude, nous avons conservé les indicateurs clés reflétant directement la santé financière (par exemple, chiffre d'affaires, bénéfice net, capitaux propres, postes principaux du bilan, ratios financiers essentiels) et ajouté des variables non financières (localisation géographique, code de région, code NAF, taille en nombre d'employés) afin de permettre au modèle de prendre en compte à la fois des facteurs macro et microéconomiques.

Dans cette étude, les données ont été extraites de la plateforme Orbis en utilisant la fonctionnalité de filtrage avancée. Conformément aux limitations techniques de l'outil, chaque extraction est réalisée par lot maximal de 2 300 entreprises.

Ainsi, nous avons procédé à :

7 fichiers au format .xlsx contenant les entreprises positives (défaillantes)

8 fichiers au format .xlsx contenant les entreprises négatives (en activité)

Ces fichiers contiennent chacun l'historique financier et les informations non financières correspondant à un horizon de dix ans.

Après l'extraction, l'ensemble des fichiers a été téléversé sur Google Drive afin de faciliter l'accès et le traitement ultérieur dans un environnement collaboratif, notamment avec Google Colab pour le prétraitement et la modélisation.

3.1.1.2 Choix et justification des variables

Bien que les variables non financières aient été démontrées dans plusieurs travaux comme ayant un impact positif sur la prédiction de la faillite des entreprises (Cheng-Ying, 2004), les variables financières demeurent néanmoins le principal fondement de cette prédiction (Kanapickienė, Kanapickas, Nečiūnas, 2023; Altman, Iwanicz-Drozdowska, Laitinen, Suvas, 2015).

Les principales variables conservées sont (noms principaux sans déclinaison par année)

:

Table 3.1: Principales variables retenues pour l'étude

Variables financières	Variables non financières	Variable cible
Chiffre d'affaires	Localisation géographique	Statut opérationnel
Résultat brut	Code de région	
Résultat net	Code NAF	
Flux de trésorerie	Nombre d'employés	
Total de l'actif	Durée d'enregistrement	
Capitaux propres	Délai de recouvrement des créances	
Ratio actuel	Part du chiffre d'affaires à l'export	
Marge bénéficiaire	Dépenses de R&D / chiffre d'affaires	
ROE (avant impôt)		
ROCE (avant impôt)		
Ratio de solvabilité (sur actif)		
Actif circulant total		
Passif circulant total		
ROA (avant impôt)		
ROE (résultat net)		
ROCE (résultat net)		
ROA (résultat net)		
Marge brute		
Marge EBIT après remise		
Marge EBIT		
Flux de trésorerie / chiffre d'affaires		
Valeur d'entreprise / EBITDA		
Capitalisation boursière / flux de trésorerie d'exploitation		
Rotation des actifs nets		
Couverture des intérêts		
Rotation des actions		
Ratio de liquidité		
Indice de rotation des actionnaires		
Ratio de solvabilité (sur passif)		
Effet de levier		

La sélection des variables constitue une étape fondamentale dans la construction d'un modèle prédictif de défaillance. Les indicateurs choisis doivent refléter de manière fiable la santé financière d'une entreprise, tout en intégrant des aspects structurels, sectoriels et géographiques susceptibles d'influencer son risque de faillite. Les variables retenues dans cette étude proviennent de la base Orbis (Bureau van Dijk), qui fournit des informations financières et non financières détaillées pour un grand nombre d'entreprises françaises.

1. Identifiants et informations de base SIRET : Il s'agit de l'identifiant unique d'un établissement (SIREN + NIC), indispensable pour assurer la correspondance entre différentes sources de données (par exemple INSEE, fichiers fiscaux) et pour effectuer un suivi longitudinal de l'entreprise. Bien que cette variable ne soit pas directement prédictive, elle est essentielle pour garantir l'intégrité des données et éviter les doublons

Code APE : Ce code à 4 chiffres, défini par l'INSEE, indique l'activité principale exercée par l'entreprise. Il est crucial dans la mesure où les risques de faillite varient fortement selon le secteur d'activité (par exemple, le BTP ou la restauration présentent des taux de défaillance historiquement plus élevés)

Département et Région : Ces variables géographiques permettent d'intégrer des différences territoriales en termes de dynamisme économique, de tissu industriel et de conjoncture régionale. Par exemple, certaines régions peuvent être plus exposées à des chocs sectoriels spécifiques ou présenter des conditions macroéconomiques moins favorables (Bragoli et al., 2021)

2. Variables financières fondamentales

Chiffre d'affaires : Représente le volume d'activité et la capacité de l'entreprise à générer des revenus. Un chiffre d'affaires faible ou en forte baisse peut indiquer une perte de parts de marché ou un affaiblissement structurel, souvent précurseur de difficultés financières (Altman, 1968)

Résultat net : Mesure le bénéfice ou la perte après prise en compte de toutes les charges et produits. Un résultat net négatif récurrent est un signal d'alerte important, indiquant que l'entreprise n'est pas en mesure de couvrir ses coûts par ses revenus (Ohlson, 1980).

Excédent Brut d'Exploitation (EBE) : Indique la performance opérationnelle avant amortissements et charges financières. Il mesure la capacité de l'entreprise à générer

du cash à partir de ses opérations principales, indépendamment de sa structure de financement. Une EBE durablement négative est fortement corrélée au risque de faillite (Laitinen, 1991).

Fonds propres : Mesure la valeur nette détenue par les actionnaires après déduction des dettes. Un niveau de fonds propres élevé traduit une meilleure capacité d'absorption des pertes, réduisant le risque de cessation d'activité (Beaver, 1966).

Taux d'endettement : Évalue le poids des dettes par rapport aux capitaux propres ou aux actifs. Un endettement excessif accroît la vulnérabilité de l'entreprise face aux variations de trésorerie et aux hausses de taux d'intérêt (Altman, 2000).

ROE (Return on Equity) : Rendement des capitaux propres. Cet indicateur exprime la rentabilité pour les actionnaires et, indirectement, la performance globale de l'entreprise. Un ROE négatif prolongé est souvent lié à un risque de défaillance élevé (Beaver, 1968).

ROA (Return on Assets) : Rendement des actifs. Il mesure l'efficacité avec laquelle l'entreprise utilise ses actifs pour générer des bénéfices. Un ROA faible ou négatif indique une utilisation inefficace des ressources (Laitinen, 1992).

ROCE (Return on Capital Employed) : Rendement du capital employé. Il reflète la rentabilité opérationnelle par rapport à l'ensemble des capitaux investis. Un ROCE faible peut traduire une inefficacité opérationnelle persistante (Gentry et al., 1985).

Cash-flow / Chiffre d'affaires : Rapporte les flux de trésorerie générés aux ventes totales, permettant d'évaluer la qualité des revenus et leur transformation en liquidités. Un faible ratio est signe de tensions de trésorerie (Beaver, 1966).

3. Variables structurelles et de ressources Tranche effectifs : Taille de l'entreprise mesurée par le nombre de salariés. Les petites entreprises disposent souvent de moins de marges financières et organisationnelles pour absorber les chocs économiques (Mellahi Wilkinson, 2004).

Durée d'existence : Calculée à partir de la date de création, elle permet de distinguer les jeunes entreprises, plus vulnérables, des structures établies, généralement plus résilientes (Thornhill Amit, 2003).

Export / Chiffre d'affaires : Proportion des ventes à l'export. Cette variable reflète

l'exposition aux marchés étrangers et aux risques associés (taux de change, demande internationale) (Wagner, 2012).

4. Avantages de la sélection Le choix de ces variables repose sur plusieurs critères :

Pertinence théorique : Chaque variable est documentée dans la littérature comme ayant une influence sur le risque de faillite (Altman, 1968 ; Ohlson, 1980 ; Beaver, 1966).

Disponibilité et qualité des données : Les indicateurs retenus présentent un taux de complétude élevé dans Orbis et sont comparables entre entreprises.

Pouvoir explicatif et interprétabilité : Les variables financières clés sont connues des analystes, ce qui facilite l'explication des prédictions auprès des décideurs.

Complémentarité : La combinaison de variables financières, structurelles et géographiques permet au modèle d'intégrer à la fois la santé interne de l'entreprise et son environnement externe.

En résumé, la sélection opérée maximise à la fois la robustesse statistique et la pertinence opérationnelle, tout en restant compatible avec les contraintes de données du modèle.

La proportion élevée de variables en `object` suggère deux causes principales : (i) des indicateurs financiers ont été importés sous forme de chaînes (par ex. avec séparateurs de milliers, symboles de pourcentage ou espaces), (ii) après fusion de plusieurs sources, les types et les conventions de nommage n'ont pas été harmonisés. Ce problème est fréquent sur les ratios financiers (ROE, marge, levier, etc.). Pour éviter les conversions implicites de type et la perte d'information, les colonnes financières de type panel (`N`, `N-1`, ..., `N-9`) seront converties explicitement en format numérique et renommées de manière standardisée¹.

3.1.1.3 Justification de la profondeur historique

Le choix d'une profondeur historique de dix années pour la collecte et l'exploitation des données dans ce travail repose sur plusieurs considérations à la fois théoriques, empiriques et pratiques.

¹La reconnaissance des colonnes panel repose sur l'expression `^(.*) N(?:-(\d+))?$`, séparant le nom de l'indicateur et le retard temporel, ce qui facilite le traitement par lot.

Capture des cycles économiques complets Les cycles économiques – alternance de phases d’expansion et de récession – influencent fortement la performance et la survie des entreprises. Une période de dix ans permet d’inclure au moins un cycle complet, incluant des phases de croissance, de stagnation et de contraction. Cela permet au modèle de mieux apprendre les comportements financiers et opérationnels des entreprises dans des contextes macroéconomiques variés (Altman, 2000 ; Laitinen, 1991).

Observation des signaux précurseurs de la défaillance De nombreuses études (Beaver, 1966 ; Ohlson, 1980) montrent que les signes avant-coureurs d’une défaillance peuvent apparaître plusieurs années avant l’événement. Par exemple, une détérioration progressive de la rentabilité, de la trésorerie ou de la structure financière peut commencer 5 à 7 ans avant la faillite. Un historique de dix ans permet donc de capter à la fois les signaux faibles à long terme et les changements brusques à court terme.

Prise en compte des variations sectorielles Les secteurs d’activité ont des cycles spécifiques (par exemple, la construction peut avoir des cycles plus courts, alors que l’industrie lourde évolue sur des cycles plus longs). Une profondeur de dix ans offre un horizon suffisant pour que le modèle apprenne ces patterns sectoriels et ne soit pas limité à un contexte économique ponctuel (Platt Platt, 1990).

Amélioration de la robustesse statistique En apprentissage automatique, disposer d’un historique long augmente la diversité des situations observées et réduit le risque de surapprentissage sur des configurations temporaires. Cela est particulièrement important pour des modèles non linéaires comme XGBoost ou les réseaux neuronaux, qui peuvent capter des interactions complexes si la variabilité des données est suffisante.

Alignement avec les meilleures pratiques dans la littérature Dans de nombreux travaux empiriques sur la prédiction des défaillances (Barboza et al., 2017 ; Zieba et al., 2016), l’horizon temporel retenu est souvent compris entre 5 et 10 ans. Le choix du maximum de cette plage permet d’exploiter pleinement la profondeur des bases comme Orbis, tout en restant dans un cadre temporel raisonnable pour la pertinence des données.

Compromis entre pertinence et obsolescence des données Bien que les données plus anciennes puissent apporter de la variété, elles risquent aussi de refléter des contextes réglementaires, fiscaux ou comptables obsolètes. Dix ans constituent un compromis : suffisamment long pour observer des cycles et signaux faibles, mais pas trop ancien pour éviter un biais dû à des changements structurels majeurs dans l’économie ou la

réglementation.

3.1.2 Prétraitement et qualité des données

Le prétraitement des données a toujours été l'une des étapes les plus importantes de l'apprentissage automatique. (Rahm & Do 2000 ; Batini & Scannapieco 2006)

3.1.2.1 Analyse exploratoire et diagnostic de complétude

Cette section présente un examen structurel et un diagnostic de la complétude des données brutes, afin d'évaluer leur adéquation et leur robustesse pour les étapes ultérieures d'ingénierie des variables et de modélisation. L'aperçu des données est le suivant : **34 027** lignes et **425** colonnes (`shape=(34027, 425)`), avec une prédominance de colonnes au format `object` (**422**), contre seulement **2** colonnes en `float64` et **1** en `int64`. La mémoire occupée est d'environ **546,5 Mo**. Les colonnes s'étendent de `index` à `Operating Status`, comme l'indique l'aperçu des `dtypes`: `float64(2)`, `int64(1)`, `object(422)`.

L'analyse des taux de valeurs manquantes par colonne montre trois grandes familles à forte absence :

- **Solvency Ratio (basé sur les dettes)** : taux de manquants de N à N-9 compris entre **0,400** et **0,498** (ex. N: 0,4977 ; N-1: 0,4692).
- **Stock Turnover** : taux d'environ **0,365–0,409** (ex. N: 0,4091 ; N-9: 0,3685).
- **Shareholder Liquidity** : taux proches de **0,292–0,306** (ex. N: 0,3008 ; N-2: 0,2918 ; N-9: 0,3011).

En dehors de ces familles, la plupart des ratios financiers ont des taux de manquants inférieurs à **0,15** (ex. **Equity Turnover** N : 0,1538), et de nombreuses mesures comptables (revenu, marge brute, total actif, résultat net, effectifs) sont complètes sur toutes les périodes (**0,0000**). La variable cible `Operating Status` ne présente aucune valeur manquante.

Forme de la distribution et « effet coude ». En classant les colonnes par taux de manquants décroissant, on observe un écart net entre **0,30** et **0,15** : après la famille **Shareholder Liquidity** ($\approx 0,29$ – $0,31$), le taux chute brusquement à **0,1538** (**Equity**

Turnover N), puis descend rapidement sous 0,11. Cette rupture correspond à un « *coude* » : au-dessus, des familles à forte absence systématique ; en dessous, des variables stables et largement exploitables.

La vérification montre **0** doublons de lignes mais **39** doublons de noms de colonnes, notamment dans : ROE N à ROE N-9, Margin N-1 à Margin N-9, Current Ratio N à Current Ratio N-9, et Solvency Ratio (basé sur les actifs) N à N-9. Ces doublons proviennent souvent de fusions multiples ou d'exports avec noms identiques. Pour éviter multicollinéarité et pondération excessive, nous conservons la première occurrence et supprimons les suivantes ; en cas de contenus différents, la consolidation suit un principe de cohérence et d'intégrité. La colonne `index`, issue de fichiers externes, n'est pas un identifiant métier et a été supprimée au profit d'un `RangeIndex`.

3.1.2.2 Stratégie de traitement des valeurs manquantes

Après avoir supprimé les colonnes dupliquées et celles dont le taux de valeurs manquantes est élevé, nous avons mis en place une stratégie d'imputation hiérarchisée et explicable. Le principe général est le suivant : *assurer d'abord la cohérence temporelle, ensuite la cohérence en coupe transversale, et enfin la stabilité globale* ; en évitant strictement toute fuite d'information liée à la variable cible. On note i l'entreprise, $t \in \{0, 1, \dots, L\}$ la période en retard ($t = 0$ correspond à l'année N, $t = L$ à N-L), m l'indicateur financier (par ex. `Revenue`, `Leverage`), et $x_{i,t}^{(m)}$ sa valeur. Le groupe sectoriel est noté $g(i)$, et la variable cible est `Operating Status`.

En combinant *structure de la distribution, faisabilité de l'imputation panel* et *préservation d'information*, le seuil de suppression a été fixé à **0,29**, pour trois raisons :

1. **Alignement avec le « coude ».** Autour de 0,29–0,30 se situe la transition entre familles à forte absence et variables stables. Ce seuil permet d'éliminer l'ensemble des séries à haut taux de manquants (ex. **Solvency Ratio (basé sur les dettes)**, **Stock Turnover**, **Shareholder Liquidity**) tout en préservant les variables stables.
2. **Support à l'imputation temporelle.** Pour un taux $\leq 0,29$, la couverture atteint au moins **71%** ; sur 10 périodes (N à N-9), cela garantit ≥ 7 points observés pour l'interpolation linéaire et l'extrapolation, réduisant fortement la variance d'imputation. Au-delà, la rareté est structurelle et nuit à la qualité des estimations.

3. **Compromis signal/bruit.** Supprimer au-delà de 0,29 permet de retirer des familles dont les manquants proviennent de différences de définition ou d'absence systématique dans la source, tout en conservant la majorité des ratios utiles pour le modèle.

Ainsi, les colonnes avec taux $> 0,29$ sont étiquetées « forte absence et faible bénéfice d'imputation ». Dans notre jeu, cela inclut les 10 périodes de **Solvency Ratio (basé sur les dettes)**, **Stock Turnover**, et **Shareholder Liquidity** (y compris N-2 à 0,2918).

La structure des données est organisée par entreprise (lignes) et par indicateurs financiers sur plusieurs périodes (colonnes N, N-1, ..., N-9). Pour préserver la continuité temporelle et le sens économique des variables, nous appliquons une *interpolation linéaire intra-ligne* sur les observations multi-périodes d'un même indicateur.

Si, pour une entreprise i et un indicateur m , deux valeurs $x_{i,a}^{(m)}$ et $x_{i,b}^{(m)}$ sont observées aux périodes $a < b$, toute valeur manquante j telle que $a < j < b$ est estimée par :

$$\hat{x}_{i,j}^{(m)} = x_{i,a}^{(m)} + \frac{j-a}{b-a} (x_{i,b}^{(m)} - x_{i,a}^{(m)}), \quad a < j < b.$$

Pour les valeurs manquantes en début ou fin de série, nous appliquons une extrapolation par le plus proche voisin (maintien du dernier point connu) (Carpenter Kenward, 2013). Cette étape est réalisée uniquement *au sein de l'entreprise*, sans utiliser d'informations d'autres entreprises ni de la variable cible, afin d'éviter toute fuite d'information ou contamination inter-entreprises (Lepot, Aubin, Clemens, 2017).

Les valeurs manquantes restantes après l'interpolation temporelle peuvent être dues à des absences complètes de période, à des suppressions d'anomalies ou à des manques dans la source. Pour assurer la comparabilité en coupe transversale, nous réalisons une imputation *au niveau sectoriel* : les données sont regroupées selon **Industry classification** et les valeurs manquantes sont remplacées par la médiane du groupe (Little Rubin, 2019). Soit $\tilde{x}_k^{(h)}$ la médiane du groupe h pour la variable k :

$$\tilde{x}_k^{(h)} = \text{median}\{x_k : g(i) = h\}.$$

Si $g(i) = h$, la valeur manquante $x_k(i)$ est remplacée par $\tilde{x}_k^{(h)}$. L'utilisation de la médiane, moins sensible aux valeurs extrêmes que la moyenne, permet une estimation plus stable (Little Rubin, 2019). Cette étape repose sur l'hypothèse de comparabilité sectorielle : les entreprises d'un même secteur présentent des structures financières proches.

Si la variable est globalement peu renseignée dans un secteur donné (médiane indisponible), nous utilisons la médiane de l'ensemble de l'échantillon :

$$\tilde{x}_k^{(\text{global})} = \text{median}\{x_k \text{ pour tout } i\}.$$

Ce niveau garantit que toutes les variables numériques sont complètes avant l'entrée dans le modèle, évitant la perte d'observations liée à des secteurs peu renseignés et optimisant l'utilisation des données.

3.1.2.3 Traitement des variables catégorielles et de la variable cible

Pour les variables catégorielles telles que `Name`, `PC` ou `Industry classification`, nous utilisons un indicateur “Unknown” ou la valeur la plus fréquente (mode) plutôt qu'une imputation numérique, afin d'éviter l'introduction de relations linéaires artificielles et de conserver l'information sur le « manque ». Si la valeur la plus fréquente est disponible, elle est prioritaire, sinon nous utilisons “Unknown” (Schafer Graham, 2002).

Pour la variable cible `Operating Status`, aucune imputation n'est réalisée ; les observations avec étiquette manquante sont supprimées. En apprentissage supervisé, les étiquettes doivent être réelles pour guider la mise à jour des paramètres ; une imputation introduirait un biais difficile à contrôler, surtout en cas de classes déséquilibrées. (He Garcia, 2009)

3.1.2.4 Robustesse et prévention des fuites d'information

Cette stratégie présente les caractéristiques suivantes : (i) *Cohérence économique* : interpolation temporelle intra-entreprise, respectant la nature lissée des indicateurs financiers ; puis médiane sectorielle pour maintenir la comparabilité en coupe transversale ; (ii) *Résistance aux anomalies* : la médiane limite l'influence des valeurs extrêmes et réduit les biais d'imputation ; (iii) *Traçabilité et reproductibilité* : génération de rapports comparant les taux de valeurs manquantes avant/après traitement, documentant l'impact pour chaque variable ; (iv) *Prévention des fuites d'information* : aucune utilisation de la variable cible ou de données futures, uniquement les historiques internes et informations sectorielles.

3.1.2.5 Procédure de mise en œuvre (reproductible)

Pour assurer la reproductibilité et l'homogénéité du traitement, la séquence est la suivante :

1. Supprimer la colonne `index` et réinitialiser l'index ; nettoyer les espaces dans les noms de colonnes.
2. Identifier les colonnes temporelles avec l'expression régulière `^(.*)\sN(?:-(\d+))?$` (ex. `Revenue N`, `Revenue N-1`, ...) et forcer leur conversion en numérique (`NaN` si échec).
3. Pour chaque groupe d'indicateurs m , appliquer l'interpolation linéaire intra-ligne par ordre chronologique ($N-9$ vers N), puis extrapoler aux extrémités par voisin proche.
4. Remplacer les valeurs manquantes numériques par la médiane sectorielle ; si indisponible, utiliser la médiane globale. Exclure explicitement `PC` et `Operating Status`.
5. Pour les colonnes catégorielles, utiliser le mode ou "`Unknown`".
6. Supprimer les observations avec étiquette cible manquante.
7. Générer et sauvegarder un rapport comparatif des taux de valeurs manquantes avant/après traitement.

3.1.3 Traitement des données

Après avoir effectué le traitement des valeurs manquantes et la normalisation, les données ont été restructurées de manière systématique afin de pouvoir alimenter plusieurs types de modèles d'apprentissage automatique, incluant à la fois des modèles de type *coupe transversale* et des modèles de *séries temporelles*. L'objectif est de produire, dans des conditions strictement comparables, des jeux de données de caractéristiques correspondant à différentes profondeurs historiques (1 an, 3 ans, 10 ans), afin d'analyser l'impact de la longueur de l'historique sur les performances prédictives.

3.1.3.1 Classification des types de variables

Les colonnes de caractéristiques initiales peuvent être divisées en deux catégories :

- **Variables statiques** : attributs invariants sur la période étudiée, tels que la classification sectorielle (`Industry classification`), le code postal (`PC`), etc. Ces variables ne comportent pas de suffixe temporel.

- **Variables dynamiques** : indicateurs financiers et opérationnels évolutifs, tels que *Revenue N*, *Revenue N-1*, *Leverage N-3*, etc. Ces colonnes comportent un marquage de retard (*lag*) dans leur nom, où *N* désigne l'année courante et *N-k* l'année située *k* ans avant l'année courante.

Un traitement automatisé des noms de colonnes permet de séparer clairement les ensembles de variables statiques et dynamiques, ce qui sert de base à la génération ultérieure des jeux de données transversaux et temporels.

3.1.3.2 Construction des jeux de données

Pour les modèles qui ne traitent pas explicitement la dimension temporelle, tels que la régression logistique, les machines à vecteurs de support (SVM), les arbres de gradient boosting (XGBoost) ou les modèles *TabTransformer*, trois versions de jeux de données ont été construites :

- **Jeu 1 an (1Y)** : variables statiques et variables dynamiques de l'année courante (*N*) uniquement.
- **Jeu 3 ans (3Y)** : variables statiques et variables dynamiques des trois dernières années (*N*, *N-1*, *N-2*).
- **Jeu 10 ans (10Y)** : variables statiques et variables dynamiques des dix dernières années (*N* à *N-9*).

La procédure garantit que les différences entre ces versions ne proviennent que de la profondeur historique, toutes les autres étapes de traitement (encodage, normalisation) étant identiques, ce qui facilite la comparaison directe des performances.

Pour les modèles exploitant la dimension temporelle, tels que les réseaux à mémoire à long terme (LSTM), les unités récurrentes à portes (GRU), les réseaux convolutifs temporels (TCN) ou le *Temporal Fusion Transformer* (TFT), les variables dynamiques ont été organisées en représentations tensorisées :

- **Tenseur de séquence dynamique** : de forme (nombre_d'échantillons, longueur_de_séquence, nombre_de_variables) avec la séquence ordonnée du plus ancien au plus récent.

- **Matrice des variables statiques** : de forme (nombre_d'échantillons, nombre_de_variables_statiques) utilisée comme entrée complémentaire pour les modèles capables de combiner informations statiques et dynamiques (par ex. TFT).
- **Tenseur combiné dynamique+statique** : de forme (nombre_d'échantillons, longueur_de_séquence, nombre_statiques), obtenu en répliquant les variables statiques à chaque pas temporel, adapté aux architectures traitant toutes les entrées par séquence (LSTM, GRU, etc.).

Seules les variables dynamiques disposant d'un historique complet pour la période considérée ont été retenues, afin d'assurer la cohérence dimensionnelle des tenseurs. L'ordre temporel est uniformisé (du plus ancien au plus récent) pour garantir une lecture homogène de l'historique par les différents modèles.

3.1.3.3 Garantie de comparabilité expérimentale

Pour assurer la comparabilité des expériences entre modèles et profondeurs temporelles :

- Les divisions des données (apprentissage, validation, test) sont effectuées après la restructuration, de manière à conserver les mêmes échantillons dans toutes les conditions expérimentales.
- Les encodeurs et les normalisateurs sont ajustés uniquement sur l'échantillon d'apprentissage, puis appliqués aux ensembles de validation et de test, afin d'éviter toute fuite d'information.
- Pour les données temporelles, les échantillons avec années manquantes dans la fenêtre historique sont exclus, garantissant l'intégrité des séquences en entrée.

Ainsi, trois profondeurs historiques (1 an, 3 ans, 10 ans) ont été préparées sous forme de données transversales et temporelles, constituant une base harmonisée pour l'évaluation systématique de multiples modèles et horizons temporels.

3.1.3.4 Reconstruction des données et ingénierie des caractéristiques

Conversion du format large au format long Les données initiales sont fournies sous forme de tableau large, chaque indicateur financier étant décliné pour dix années consécutives (nommées N, N-1, ..., N-9). Par exemple, **Revenue** N représente le chiffre

d'affaires de l'année courante, et **Revenue N-1** celui de l'année précédente. Afin de faciliter la modélisation des séries temporelles et la gestion des variables, le tableau large a été transformé en format long (*Long Format*), dans lequel chaque ligne correspond à une entreprise pour une année donnée. Une variable **year_relative** a été introduite pour indiquer le temps relatif par rapport à l'année de référence (N pour l'année courante, N-1 pour l'année précédente, etc.). Après transformation, toutes les colonnes de type N-x sont regroupées dans une seule colonne d'indicateur, et différenciées par **year_relative**.

Décalage temporel des étiquettes (Forward Shift) L'objectif de la prédiction de défaillance est d'anticiper, à partir des caractéristiques financières et opérationnelles de l'année en cours, le statut de survie de l'année suivante. Dans la structure au format long, la variable cible **Operating Status** a été décalée d'une période vers l'avant : le statut observé à l'année t est attribué à l'enregistrement de l'année $t - 1$, formant la nouvelle colonne **Operating Status ($t \rightarrow t+1$)**. Ainsi, chaque observation contient comme variables explicatives les données de l'année en cours et, comme étiquette, le statut réel de l'année suivante. Les enregistrements de l'année la plus récente (N), pour lesquels aucune étiquette future n'est disponible, ont été exclus.

Prétraitement des variables catégorielles Le format long contient plusieurs variables de type catégoriel, parmi lesquelles :

- **PC** (code postal) : seuls les deux premiers chiffres sont conservés afin de représenter la localisation à l'échelle régionale ;
- **Industry classification** (classification sectorielle) : classification fine avec plusieurs centaines de modalités ;
- **year_relative** (année relative) : position temporelle de l'observation.

Pour limiter la forte dimensionnalité et la sparsité induites par un encodage *One-Hot* direct, la stratégie suivante a été appliquée :

1. **PC** : conservation des deux premiers chiffres suivie d'un encodage *One-Hot*, avec regroupement des modalités peu fréquentes (fréquence $< 1\%$) sous l'étiquette "Autre".

2. **Industry classification** : utilisation de l’encodage par cible (*Target Encoding*), remplaçant chaque modalité par la moyenne du taux de défaillance correspondant, afin de réduire la dimension tout en préservant l’information statistique pertinente.
3. **year_relative** : traitée comme variable numérique ordinale, normalisée sans encodage *One-Hot*.

Normalisation des variables numériques Tous les indicateurs financiers continus (chiffre d’affaires, marges, ratios d’endettement, etc.) ainsi que la variable numérique `year_relative` ont été normalisés selon la formule du Z-score :

$$x' = \frac{x - \mu}{\sigma}$$

où μ et σ représentent respectivement la moyenne et l’écart-type calculés sur l’échantillon d’apprentissage. Cette normalisation supprime l’effet des différences d’unités et empêche les variables à grande échelle d’influencer disproportionnellement l’apprentissage.

Construction de la matrice des caractéristiques et du vecteur cible Après prétraitement, les variables catégorielles encodées et les variables numériques normalisées ont été fusionnées pour former la matrice finale de caractéristiques X . La variable **Operating Status** ($t \rightarrow t+1$) constitue le vecteur cible y . Cette structure $X-y$ est directement exploitable pour l’entraînement et l’évaluation de différents modèles, qu’il s’agisse de méthodes classiques (régression logistique, SVM, XGBoost) ou de modèles intégrant la dimension temporelle (TabTransformer, LSTM, GRU, etc.).

3.1.3.5 Traitement du déséquilibre des classes

Après la conversion des données initiales en format long (*long format*), nous avons constaté une modification notable de la répartition des classes. Dans les données initiales au format transversal, le rapport entre les entreprises en faillite (étiquette 1) et celles en activité (étiquette 0) était d’environ 1 : 2, ce qui correspondait à une distribution relativement équilibrée. En revanche, dans la structure en format long, chaque entreprise est marquée comme “en activité” (0) pour toutes les années précédant la faillite et seulement comme “en faillite” (1) pour l’année où celle-ci survient. Cette transformation a entraîné une baisse importante de la proportion de la classe minoritaire. Les statistiques obtenues sont les suivantes :

Faillite (1) : $\approx 7,39\%$, Activité (0) : $\approx 92,61\%$.

Une telle distribution fortement déséquilibrée peut conduire, dans un contexte d'apprentissage supervisé, à un modèle favorisant la prédiction de la classe majoritaire (entreprises actives), ce qui réduit considérablement le rappel (*recall*) pour la classe minoritaire (faillite). Ce problème est particulièrement critique dans les tâches de détection d'événements rares, où la sensibilité à la classe minoritaire est essentielle pour l'utilité opérationnelle du modèle.

Analyse du problème La structure en format long introduit des étiquettes répétées pour la classe majoritaire. Ainsi, lorsqu'une entreprise fait faillite à l'année N , les années $N - 1, N - 2, \dots$ sont toutes annotées comme 0. Cette particularité de la distribution des étiquettes accentue le déséquilibre, rendant difficile pour le modèle l'apprentissage d'une frontière de décision fiable pour la classe minoritaire. De plus, dans un contexte de fort déséquilibre, les algorithmes de classification classiques voient leur fonction de coût dominée par la classe majoritaire, ce qui conduit à négliger les échantillons minoritaires.

Approche adoptée Pour réduire ce biais, nous avons appliqué la méthode **SMOTE** (*Synthetic Minority Over-sampling Technique*) afin de réaliser un suréchantillonnage de la classe minoritaire pendant la phase d'entraînement. La stratégie mise en place est la suivante :

- **Application exclusive sur l'ensemble d'entraînement** : afin d'éviter toute fuite d'information, SMOTE est appliqué uniquement aux données d'entraînement ; les ensembles de validation et de test conservent la distribution réelle, garantissant ainsi la représentativité des résultats.
- **Génération d'exemples synthétiques** : SMOTE crée de nouveaux échantillons de la classe minoritaire par interpolation entre les observations existantes, jusqu'à atteindre une proportion équilibrée 1 : 1 dans l'ensemble d'entraînement.
- **Ajustement dynamique du paramètre de voisinage** : lorsque le nombre d'échantillons minoritaires est faible, la valeur par défaut $k = 5$ peut poser problème. Nous adaptons donc la valeur de k en fonction de la taille de la classe minoritaire afin de stabiliser le processus de suréchantillonnage.

Résultats obtenus Après application de SMOTE, la proportion des classes dans l'ensemble d'entraînement est passée de $0 : 1 \approx 12,6 : 1$ à un équilibre 1 : 1. Cette

amélioration de la répartition des classes fournit une base plus équilibrée pour l'entraînement des modèles (régression logistique, SVM, XGBoost, TabTransformer, etc.) et contribue à une meilleure détection de la classe minoritaire.

3.2 Configuration expérimentale

3.2.1 Méthodes de modélisation

Dans le cadre de cette recherche, trois modèles ont été sélectionnés et comparés afin d'évaluer leur performance prédictive dans la détection de la faillite d'entreprises : la régression logistique, XGBoost et TabTransformer.

Le choix de ces trois approches repose sur des critères méthodologiques et pratiques clairs. D'une part, la **régression logistique** constitue le modèle le plus couramment utilisé dans le secteur bancaire pour l'évaluation du risque de crédit, en raison de sa simplicité et de sa forte *interprétabilité*. Elle sert donc de référence indispensable dans toute comparaison empirique. D'autre part, **XGBoost** représente l'algorithme d'ensemble qui a démontré, dans de nombreuses études empiriques, une efficacité remarquable dans la prédiction des faillites d'entreprises, surpassant souvent les modèles classiques et d'autres méthodes d'apprentissage automatique. Enfin, le **TabTransformer**, qui transpose l'architecture *Transformer* aux données tabulaires, incarne une technologie émergente. Bien qu'il n'ait pas encore été utilisé pour la prédiction de faillite, il ouvre la possibilité d'explorer l'apport des approches les plus récentes du *deep learning* dans ce domaine.

Ainsi, ces trois modèles représentent respectivement : un modèle de référence hautement interprétable, un modèle d'apprentissage automatique éprouvé dans la littérature, et une innovation technologique encore inexplorée dans le champ de la prédiction des défaillances.

3.2.1.1 Régression logistique et XGBoost

La régression logistique et XGBoost représentent deux méthodes de référence largement utilisées dans la littérature sur la prédiction de faillite. La première, introduite notamment par Ohlson (1980), est historiquement le modèle le plus employé dans le secteur bancaire et du crédit, en raison de sa robustesse, de sa simplicité et surtout de son interprétabilité élevée. Elle constitue donc un point de comparaison indispensable pour évaluer toute

approche nouvelle. XGBoost, quant à lui, proposé par (Chen et Guestrin 2016), est un algorithme d'ensemble reconnu pour sa performance supérieure sur des données hétérogènes et déséquilibrées. De nombreuses études empiriques (par ex. Barboza et al., 2017) ont confirmé son efficacité dans la prédiction des défaillances. Ces deux modèles, déjà largement validés dans la littérature, sont retenus ici comme modèles de référence afin de servir de points de comparaison pertinents vis-à-vis du modèle TabTransformer, plus récent et encore peu exploré dans ce domaine.

3.2.1.2 TabTransformer

TabTransformer, introduit par Huang *et al.* (2020), est un modèle *deep learning* conçu spécifiquement pour les données tabulaires. Il repose sur l'architecture Transformer, initialement proposée pour le traitement du langage naturel, et l'adapte au contexte des variables catégorielles et numériques présentes dans les bases de données structurées.




Figure 3.1: Architecture du modèle TabTransformer

Principe général. Le modèle s'appuie sur un mécanisme d'*auto-attention* (*self-attention*) pour capturer les relations complexes entre les colonnes d'un tableau. Les variables catégorielles sont d'abord projetées dans un espace latent par des embeddings, puis traitées par plusieurs couches Transformer afin de modéliser leurs interactions explicites. Les variables numériques sont concaténées à la sortie des couches Transformer pour constituer la représentation finale de l'échantillon.

Encodage des variables catégorielles. Soit un tableau contenant d_c variables catégorielles et d_n variables numériques. Chaque variable catégorielle x_j est transformée en un vecteur dense $e_j \in \mathbb{R}^k$ par une matrice d’embedding. Ainsi, un échantillon est représenté par une séquence $(e_1, e_2, \dots, e_{d_c})$, qui constitue l’entrée du bloc Transformer. Ce choix permet de traiter chaque variable comme une “position” analogue à un mot dans une phrase.

Bloc Transformer. Les vecteurs d’embedding passent ensuite par des couches d’auto-attention multi-têtes. Pour une tête d’attention donnée, le mécanisme calcule (Huang et al. 2020):

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V$$

où Q, K, V sont respectivement les matrices des requêtes, clés et valeurs dérivées des embeddings, et d_k est la dimension de chaque tête. Ce mécanisme permet à chaque variable catégorielle d’interagir avec toutes les autres et de pondérer leur importance relative.

Concaténation avec les variables numériques. (Huang et al. 2020) La sortie des couches Transformer, notée $Z \in \mathbb{R}^{d_c \times k}$, est aplatie et concaténée avec les variables numériques $(x_{d_c+1}, \dots, x_{d_c+d_n})$. On obtient ainsi un vecteur final h :

$$h = [\text{Flatten}(Z); x_{d_c+1}, \dots, x_{d_c+d_n}]$$

qui sert d’entrée à un perceptron multicouche (MLP) pour la tâche de classification.

Avantages et contributions. TabTransformer présente plusieurs atouts majeurs :

- Il capture explicitement les dépendances entre variables catégorielles, contrairement aux approches classiques (*One-Hot*, *Target Encoding*) qui traitent chaque variable de manière indépendante.
- Il fournit des représentations latentes riches et interprétables grâce aux poids d’attention, permettant d’identifier quelles variables interagissent le plus pour prédire une faillite.
- Il s’intègre naturellement avec les variables numériques, offrant un cadre unifié pour les données tabulaires mixtes.

Ainsi, TabTransformer ouvre une nouvelle voie pour l'application des architectures Transformer aux données tabulaires et, dans notre contexte, constitue une approche innovante pour la prédiction de faillite d'entreprises, encore peu explorée dans la littérature existante.

3.2.2 Métrique d'évaluation

Le problème de la prédiction de faillite peut être formulé comme un problème de classification binaire, dont l'objectif est de déterminer, à partir d'un ensemble d'indicateurs financiers ou d'autres données pertinentes, si une entreprise est susceptible de faire faillite. Dans les problèmes de classification fortement déséquilibrés, tels que la prédiction de faillite d'entreprises, l'utilisation du seul taux de précision (*accuracy*) peut être trompeuse. En effet, un classificateur qui prédirait systématiquement la classe majoritaire (entreprises saines) atteindrait une précision élevée, mais échouerait totalement à détecter les entreprises en difficulté. Pour pallier ce biais, l'évaluation repose sur plusieurs indicateurs dérivés de la matrice de confusion (Gu, Zhu, Cai, 2009):

- **Vrais positifs (TP)** : nombre d'entreprises défaillantes correctement prédites comme défaillantes.
- **Faux positifs (FP)** : nombre d'entreprises saines prédites à tort comme défaillantes.
- **Vrais négatifs (TN)** : nombre d'entreprises saines correctement identifiées.
- **Faux négatifs (FN)** : nombre d'entreprises défaillantes prédites à tort comme saines.

À partir de ces quantités, les mesures suivantes sont calculées :

Précision globale (Accuracy). (Powers, 2011)

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Cet indicateur mesure la proportion totale de prédictions correctes, mais reste sensible au déséquilibre des classes.

Rappel (Recall) ou sensibilité.(Stojanović et al., 2014)

$$Recall = \frac{TP}{TP + FN}$$

Il indique la capacité du modèle à identifier correctement les entreprises défaillantes. Un rappel élevé signifie que peu d'entreprises en faillite sont manquées.

Spécificité (Specificity).(Stojanović et al., 2014)

$$Specificity = \frac{TN}{TN + FP}$$

Elle mesure la capacité du modèle à reconnaître correctement les entreprises non défaillantes.

Précision (Precision).(Stojanović et al., 2014)

$$Precision = \frac{TP}{TP + FP}$$

Elle exprime la proportion d'entreprises réellement défaillantes parmi celles prédites comme telles.

F1-score.(van Rijsbergen 1979)

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Cet indicateur combine la précision et le rappel en une seule mesure harmonique, ce qui permet d'évaluer l'équilibre entre la capacité du modèle à identifier correctement les entreprises défaillantes (rappel) et à limiter les fausses alertes (précision).

Erreur de type I (Type I Error).(Powers, 2011)

$$Type\ I = \frac{FP}{TN + FP} = 1 - Specificity$$

Elle correspond aux entreprises saines à tort classées comme défaillantes (faux positifs).

Erreur de type II (Type II Error).(Powers, 2011)

$$Type\ II = \frac{FN}{TP + FN} = 1 - Recall$$

Elle correspond aux entreprises défaillantes à tort classées comme saines (faux négatifs). Dans le contexte de la prédiction de faillite, l'erreur de type II est particulièrement critique, car elle revient à ignorer une entreprise risquant de faire défaut.

3.2.3 Environnement expérimental

Les expériences ont été menées dans un environnement de calcul basé sur **Google Colab**, exécuté sur le cloud. Afin d'accélérer l'entraînement des modèles de type deep learning, un GPU **NVIDIA A100** a été utilisé. L'ensemble du code a été développé en langage **Python 3.11**, avec les bibliothèques et outils suivants :

- Prétraitement des données : la gestion et la manipulation ont été réalisées avec les bibliothèques **pandas** et **numpy**.
- Équilibrage des classes : pour traiter le déséquilibre entre entreprises actives et défaillantes, les méthodes *SMOTE* et *SMOTE-ENN* ont été implémentées grâce à la bibliothèque **imbalanced-learn**. Le SMOTE et SMOTE ENN a démontré une très bonne efficacité dans plusieurs modèles.(Aljawazneh et al., 2021)
- Modèles de base : la régression logistique et la machine à vecteurs de support (SVM) ont été mises en œuvre avec **scikit-learn**.
- Gradient boosting : le modèle *XGBoost* a été entraîné via la bibliothèque officielle **xgboost**.
- Modèles de type Transformer : le *TabTransformer* a été développé et entraîné avec le framework **PyTorch**, via une implémentation adaptée aux données tabulaires.
- Évaluation : les métriques (accuracy, recall, specificity, precision, F1, type I error, type II error, et AUC) proviennent de **scikit-learn**.

Toutes les expérimentations ont été exécutées dans un environnement reproductible, avec une graine aléatoire fixée (**random_state = 42**) afin d'assurer la comparabilité des résultats.

3.2.4 Principaux hyperparamètres considérés

Table 3.2: Hyperparamètres optimaux retenus pour chaque modèle

Modèle	Hyperparamètre	Valeur optimale
Régression logistique	Pénalisation (C)	1.0
Régression logistique	Fonction de coût	Log-loss (binary cross-entropy)
XGBoost	Profondeur max. (<code>max_depth</code>)	7
XGBoost	Nombre d'estimateurs	1000 (early stopping $\approx$ 980)
XGBoost	Taux d'apprentissage	0.05
XGBoost	Sous-échantillonnage	0.8
XGBoost	Colonnes par split	0.8
TabTransformer	Dimension cachée (<code>dim</code>)	32
TabTransformer	Nombre de têtes	8
TabTransformer	Nombre de couches	4
TabTransformer	Dropout	0.1
TabTransformer	Taille du batch	512
TabTransformer	Optimiseur	AdamW ($lr = 1 \times 10^{-3}$)
SMOTE/SMOTE-ENN	Nombre de voisins (k)	5
SMOTE/SMOTE-ENN	Stratégie	auto (équilibre 1 : 1)
SMOTE/SMOTE-ENN	Méthode de nettoyage	ENN (suppression voisins majoritaires)

La performance des méthodes de type apprentissage automatique ou profond est fortement influencée par le choix de leurs hyperparamètres. En effet, certains d'entre eux ont un impact déterminant sur le processus d'optimisation, la capacité de généralisation et la stabilité des modèles. Le choix des valeurs optimales dépend largement du problème étudié et requiert généralement une phase d'expérimentation approfondie. Les principaux hyperparamètres retenus dans cette étude sont les suivants :

- **Taux d'apprentissage (Learning Rate)** : hyperparamètre central pour les modèles *deep learning* (TabTransformer) et XGBoost, qui règle la vitesse d'actualisation des poids. Un taux trop élevé peut entraîner une divergence ou une convergence vers un minimum sous-optimal, alors qu'un taux trop faible ralentit l'entraînement.
- **Nombre d'époques (Epochs)** : correspond au nombre de passages complets sur l'ensemble des données d'entraînement dans les modèles neuronaux comme le TabTransformer.
- **Taille du batch (Batch Size)** : nombre d'exemples utilisés pour chaque mise à jour des poids dans les réseaux de neurones.

- **Fonctions d'activation** : la fonction **ReLU** (*Rectified Linear Unit*) est utilisée dans le TabTransformer, définie par

$$f(x) = \max(0, x) = \begin{cases} x, & \text{si } x \geq 0 \\ 0, & \text{sinon} \end{cases}$$

tandis que la fonction **Sigmoid** est utilisée en sortie pour la classification binaire, afin de produire une probabilité dans l'intervalle $(0, 1)$.

- **Dropout** : technique de régularisation appliquée dans le TabTransformer pour réduire le surapprentissage, consistant à « masquer » aléatoirement certaines unités pendant l'entraînement.
- **Fonction de perte** : la fonction *Binary Cross-Entropy* est utilisée pour mesurer l'écart entre la distribution prédite et la distribution réelle des classes.
- **Optimiseur** : l'optimisation des réseaux de neurones repose sur l'algorithme **AdamW**, qui adapte dynamiquement le taux d'apprentissage au cours de l'entraînement.
- **Paramètres XGBoost** : incluent notamment la profondeur maximale des arbres (`max_depth`), le taux d'apprentissage, le nombre d'estimateurs (`n_estimators`), la proportion de sous-échantillonnage (`subsample`) et la fraction de caractéristiques utilisées à chaque split (`colsample_bytree`).
- **Paramètres de rééchantillonnage** : pour les méthodes **SMOTE** et **SMOTE-ENN**, les principaux paramètres sont le nombre de voisins k (dans l'algorithme des plus proches voisins), la stratégie de sur-échantillonnage (`sampling_strategy`) ainsi que les paramètres associés à la phase de nettoyage des instances (ENN).

Il est à noter que tous les hyperparamètres ne sont pas utilisés dans chacun des modèles considérés. Leur configuration spécifique ainsi que les valeurs retenues pour les expériences sont détaillées dans les Tableaux 3.2.

3.3 Résultats

3.3.1 Analyse des résultats expérimentaux

Table 3.3: Résultats comparatifs des modèles

Modèle	Méthode	Accuracy	Recall	Specificity	Precision	Type I Err.	Type II Err.
Logistic	SMOTE	0.5544	0.6661	0.5455	0.1047	0.4545	0.3339
	SMOTE-ENN	0.5270	0.6970	0.5134	0.1025	0.4866	0.3030
XGBoost	SMOTE	0.9931	0.9623	0.9956	0.9456	0.0044	0.0377
	SMOTE-ENN	0.9878	0.9676	0.9894	0.8795	0.0106	0.0324
TabTransformer	SMOTE	0.9699	0.9608	0.9706	0.7230	0.0294	0.0392
	SMOTE-ENN	0.9567	0.9658	0.9560	0.6364	0.0440	0.0342

Les résultats des trois modèles principaux (Régression logistique, XGBoost et TabTransformer) combinés avec les techniques de rééchantillonnage (**SMOTE** et **SMOTE-ENN**) sont présentés dans le Tableau 3.3.

On observe tout d’abord que la **régression logistique**, bien que relativement simple, obtient des résultats faibles en précision (environ 0.10), mais atteint des valeurs de **recall** proches de 0.70 après SMOTE-ENN. Cela traduit une capacité à identifier correctement une partie des entreprises en difficulté, mais au prix d’un taux élevé de fausses alertes (Type I Error supérieur à 45%).

À l’inverse, **XGBoost** présente les performances les plus élevées parmi tous les modèles, avec une précision (0.94 en SMOTE) et une spécificité (0.996) quasi parfaites, accompagnées d’un très faible taux d’erreur de type I ($< 1\%$). L’utilisation de SMOTE-ENN réduit légèrement la précision (0.88) mais améliore la sensibilité, ce qui confirme la robustesse du modèle même sur un jeu de données fortement déséquilibré.

Le **TabTransformer**, basé sur les architectures de type Transformer, montre un compromis intéressant : avec SMOTE, il obtient une précision intermédiaire (0.72) et un rappel (0.96), tandis qu’avec SMOTE-ENN, il améliore encore le rappel (0.966) au détriment d’une baisse de la précision (0.636). Ces résultats suggèrent que le TabTransformer parvient à capturer des relations complexes entre les variables tabulaires, mais reste sensible au choix de la méthode de rééchantillonnage.

En résumé, **XGBoost** est le modèle le plus performant en termes globaux (accuracy, precision et specificity), tandis que le **TabTransformer** se distingue par un rappel très élevé, ce qui en fait un modèle adapté aux cas où la détection des entreprises défaillantes doit primer sur la minimisation des fausses alertes. Enfin, la régression logistique conserve un intérêt comme baseline interprétable, mais ses limites de performance sont manifestes.

3.3.2 Analyse univariée

Table 3.4: Performances des variables individuelles (AUC univariée)

Index	Variable	AUC	Index	Variable	AUC
0	Revenue	0.7241	12	ROA (Net Profit)	0.5546
1	Total Assets	0.7072	13	Leverage	0.5541
2	Net Profit	0.6725	14	Market Cap / Operating CF	0.5515
3	Equity	0.6661	15	Reporting Period	0.5513
4	Cash Flow	0.6611	16	ROE	0.5461
5	Net Income	0.6408	17	ROE (Based on Pre-tax Profit)	0.5461
6	Gross Profit	0.6388	18	Credit Period	0.5434
7	Employees	0.6245	19	ROCE (Based on Pre-tax Profit) (%)	0.5425
8	Industry classification	0.6114	20	ROCE (%)	0.5425
9	Interest Coverage	0.5756	21	Gross Margin	0.4597
10	ROA	0.5634	22	Equity Turnover	0.5376
11	EV / EBITDA	0.4438	23	Margin	0.5345
			24	EBITDA Margin	0.5329
			25	ROE (Net Profit)	0.5324
			26	Current Liabilities	0.5305
			27	ROCE (Net Profit)	0.5297
			28	Export / Revenue	0.5226
			29	EBIT Margin	0.5216

Afin d'évaluer l'importance relative de chaque variable explicative, nous avons réalisé une analyse univariée basée sur l'**aire sous la courbe ROC (AUC)**. Cette approche consiste à entraîner un classifieur binaire extrêmement simple pour chaque variable individuellement, puis à calculer l'AUC obtenue en prédiction de l'état de l'entreprise (défaillante ou non).

L'objectif de ce test est double :

- **Détection de fuite d'information** : si une variable isolée présente une AUC proche de 1.0, cela peut indiquer une forte corrélation avec la cible, voire un risque de fuite de données (data leakage).
- **Analyse exploratoire de pertinence** : ce test permet d'identifier quelles variables portent le plus d'information prédictive sur la faillite, indépendamment des corrélations entre variables.

Concrètement, chaque variable X_j a été utilisée comme unique prédicteur dans un modèle de régression logistique univariée. L'AUC obtenue a ensuite été rapportée, ce qui permet de comparer les variables sur une base commune.


Les résultats montrent que certaines variables financières globales présentent une capacité discriminante notable : par exemple, le **Revenue** ($AUC \approx 0.72$), les **Total Assets** ($AUC \approx 0.71$) ou encore le **Net Profit** ($AUC \approx 0.67$). Ces variables traduisent la taille et la rentabilité de l'entreprise, facteurs historiquement reconnus comme prédictifs de la défaillance.

À l'inverse, certaines variables de ratio présentent une AUC proche de 0.5, comme par exemple **Gross Margin** ($AUC \approx 0.54$) ou **EBIT Margin** ($AUC \approx 0.52$). Cela suggère que, prises individuellement, elles ne permettent pas de distinguer efficacement les entreprises en bonne santé des entreprises défaillantes, mais elles peuvent devenir utiles lorsqu'elles sont combinées avec d'autres indicateurs au sein de modèles multivariés. Globalement, cette analyse univariée confirme la **cohérence économique des données** : les grandeurs de bilan et de résultat dominant en pouvoir explicatif, tandis que les ratios plus fins nécessitent une modélisation conjointe. De plus, l'absence de variables avec une AUC anormalement proche de 1.0 suggère qu'aucune fuite directe d'information vers la cible n'est présente.

3.3.3 Analyse interprétative avec SHAP


Afin de comprendre l'impact des variables sur la prédiction du modèle TabTransformer, nous avons utilisé la méthode **SHAP (SHapley Additive Explanations)**. Cette approche permet d'évaluer la contribution marginale de chaque variable aux décisions du modèle, aussi bien globalement (importance moyenne) que localement (au niveau des observations individuelles).

Figure 3.2: Importance globale des variables selon la valeur absolue moyenne de SHAP.




La Figure 3.2 montre les variables les plus influentes dans le modèle TabTransformer. On constate que les indicateurs financiers **EV/EBITDA**, **Net Profit**, **Market Cap / Operating CF** et **Revenue** dominent largement l'explication des prédictions. Ces résultats confirment l'importance des grandeurs de rentabilité et de taille de l'entreprise dans la prédiction de la défaillance. Cela est cohérent avec la littérature classique : Ohlson (1980) mettait déjà en avant la rentabilité et la taille comme déterminants de la probabilité de faillite, tandis que des travaux plus récents (Altman et al., 2017 ; Yildirim et al., 2021) ont confirmé le rôle des multiples de valorisation et des flux de trésorerie comme signaux précoces de vulnérabilité.

Figure 3.3: Graphique de dépendance SHAP pour EV/EBITDA.




La Figure 3.3 illustre la relation entre la variable EV/EBITDA et sa valeur SHAP. On observe que les faibles valeurs de EV/EBITDA augmentent fortement la probabilité prédite de faillite, ce qui est économiquement cohérent : un multiple EV/EBITDA très bas reflète souvent une faible valorisation, signalant soit des bénéfices insuffisants, soit une perception négative du marché. En d’autres termes, le modèle capte un mécanisme proche de celui identifié par Altman (1968) dans son Z-score, où une rentabilité réduite est un indicateur précurseur de défaillance. Pour un décideur financier, cela souligne l’importance de surveiller en priorité les entreprises présentant des multiples anormalement bas, car elles concentrent une part élevée du risque.

Figure 3.4: Graphique de dépendance SHAP pour Net Profit.



La Figure 3.4 montre que des profits négatifs ou très faibles sont associés à une augmentation significative du risque de défaillance prédite par le modèle. À l'inverse, un Net Profit élevé contribue à réduire la probabilité de faillite. Cette observation est en accord avec la littérature financière, qui souligne le rôle central de la rentabilité nette comme indicateur de santé économique (Beaver, 1966 ; Charalambakis Garrett, 2019). Ce résultat appuie directement notre hypothèse **H2**, selon laquelle les mesures de rentabilité sont des prédicteurs robustes de faillite. Au-delà de la confirmation statistique, cette relation offre un outil opérationnel : dans un processus de décision de crédit, une détérioration rapide du Net Profit peut constituer un signal d'alerte pour réévaluer la solvabilité d'un client.

Figure 3.5: Beeswarm plot SHAP : distribution des contributions des 20 principales variables.



La Figure 3.5 présente une vision plus détaillée des interactions variables-prédictions. On remarque que Market Cap / Operating CF et Revenue ont un impact hétérogène : les valeurs élevées (points roses) réduisent la probabilité de défaillance, tandis que les valeurs faibles (points bleus) l’augmentent. Ce résultat rejoint les travaux de Shumway (2001), qui montrait que les entreprises de grande taille et avec des flux financiers solides sont statistiquement moins susceptibles de faire faillite. Plus largement, cela confirme notre hypothèse **H3**, selon laquelle les variables de taille et de capitalisation jouent un rôle protecteur.

Enfin, les visualisations locales (non présentées ici pour des raisons de concision, voir annexes) à travers les graphes en waterfall permettent d’expliquer, pour une entreprise donnée, les facteurs spécifiques qui conduisent à une prédiction de faillite ou de survie. Ces explications locales renforcent l’utilité du modèle comme outil d’aide à la décision :


elles permettent, par exemple, à un gestionnaire de risque de justifier ex-post une décision de refus ou d'acceptation de crédit en identifiant les indicateurs financiers précis qui ont orienté le modèle.

En résumé, l'analyse SHAP ne se limite pas à une explication statistique du modèle : elle met en évidence des mécanismes économiques connus (rentabilité, taille, valorisation) et leur poids relatif dans la prédiction, confirmant ainsi la pertinence de nos hypothèses de recherche et offrant des pistes concrètes d'application dans le pilotage du risque.

3.3.4 Comparaison entre l'AUC univarié et l'importance SHAP

Table 3.5: Comparaison entre l'AUC univarié et l'importance SHAP dans le modèle TabTransformer (Top- K union). La concordance de rangs est mesurée par le Kendall's τ .

Variable	AUC univarié (test)	Mean —SHAP—	Rang AUC	Rang SHAP
Market Cap / Operating CF	0.8621	0.0748	1	3
EV / EBITDA	0.8473	0.1036	2	1
Net Profit	0.8403	0.0931	3	2
Current Assets	0.8160	0.0269	4	5
Revenue	0.7502	0.0716	5	4
Current Liabilities	0.7171	0.0033	6	17
Total Assets	0.7077	0.0030	7	23
Equity	0.6844	0.0023	8	44
Gross Profit	0.6835	0.0063	9	9
Cash Flow	0.6821	0.0032	10	19
Net Income	0.6797	0.0019	11	59
Gross Margin	0.6563	0.0141	12	7
Employees	0.6236	0.0044	13	12
Industry classification	0.6080	0.0267	14	6
Current Ratio	0.5854	0.0019	15	60



On observe que certaines variables (p. ex., *EV/EBITDA*, *Market Cap / Operating CF*, *Net Profit*) présentent à la fois un AUC univarié élevé et une importance SHAP élevée, confirmant leur pouvoir discriminant intrinsèque. Ces résultats corroborent les constats de la littérature classique (Ohlson, 1980; Altman et al., 2017), selon lesquels les ratios de rentabilité et de valorisation constituent des prédictors robustes de la faillite.

À l'inverse, d'autres variables affichent un AUC univarié modeste mais une importance SHAP notable (p. ex., *Industry classification*, *Current Assets*). Cela signifie que, prises isolément, elles discriminent peu les entreprises défaillantes des entreprises saines, mais qu'elles deviennent fortement contributives *en interaction* avec d'autres indicateurs dans le modèle multivarié. Ce phénomène illustre bien l'un des apports des modèles modernes tels que le TabTransformer, capables de capturer des effets non linéaires et des interdépendances complexes entre variables (cf. Chen & Guestrin, 2016 pour le gradient boosting, et Huang et al., 2020 pour le TabTransformer).

La mesure de concordance des rangs (Kendall's τ) quantifie ce décalage et met en évidence la complémentarité des deux analyses. Un τ relativement modeste suggère que l'information véhiculée par l'AUC univarié ne suffit pas à expliquer l'ordre d'importance des variables dans un cadre multivarié. En d'autres termes, une variable apparemment « faible » isolée peut se révéler déterminante dans un environnement interactif, ce qui justifie le recours à une approche explicative multivariée comme SHAP.

Sur le plan pratique, cette comparaison offre un double enseignement :

- Pour la sélection initiale de variables, l'AUC univarié constitue un filtre utile permettant d'éliminer les indicateurs sans valeur prédictive même combinée.
- Toutefois, s'en tenir uniquement à cette logique univariée risquerait d'écarter des variables qui, dans un modèle multivarié, jouent un rôle essentiel en interaction (ex. variables sectorielles ou structurelles).

Ainsi, l'analyse combinée AUC–SHAP rejoint les observations de Shumway (2001) et Yildirim et al. (2021), qui soulignent que la robustesse des modèles de faillite tient non seulement à la puissance individuelle de certains ratios financiers, mais aussi à la capacité du modèle à exploiter les relations entre variables. Elle confirme également notre hypothèse **H4**, selon laquelle l'explicabilité via SHAP révèle des dimensions de risque que les analyses traditionnelles, centrées sur des ratios isolés, ne sauraient détecter.

Chapter 4

Conclusion

4.1 Conditions d’application du modèle proposé

Les résultats empiriques obtenus dans cette recherche confirment que le modèle TabTransformer constitue une approche prometteuse pour la prédiction de la défaillance d’entreprises, en particulier dans le contexte des PME françaises. Cependant, son utilisation effective repose sur plusieurs conditions strictes.

Premièrement, la couverture des données est un facteur décisif. Le modèle n’est applicable que si l’ensemble des variables financières et non financières de l’année courante est disponible et correctement prétraité. Dans ce travail, la prédiction repose uniquement sur les informations de l’année N pour anticiper la survie ou la défaillance à l’année $N + 1$. Ainsi, toute entreprise présentant des données manquantes sur l’année en cours ne peut pas être intégrée au processus de prédiction.

Deuxièmement, contrairement à certains modèles probabilistes, notre démarche n’a pas fourni une probabilité explicite de faillite, mais une classification binaire alignée sur la tradition des modèles logistiques et des méthodes de *machine learning*. Or, dans les contextes opérationnels (banques, organismes publics), les décideurs souhaitent généralement disposer d’une probabilité de défaut interprétable, permettant d’établir des seuils personnalisés de décision. L’intégration d’un module probabiliste constitue donc une piste essentielle d’amélioration.

Troisièmement, la qualité du prétraitement des données demeure une condition sine qua non. Les étapes d’imputation des valeurs manquantes, de standardisation et de rééquilibrage des classes jouent un rôle central dans la performance du modèle. L’efficacité du TabTransformer dépend fortement de la cohérence de ces opérations préalables. Enfin, l’adéquation du modèle au contexte institutionnel est tout aussi déterminante : les

banques et institutions publiques recherchent un compromis entre performance prédictive et interprétabilité, ce qui justifie la mise en œuvre conjointe de modèles explicatifs (régression logistique) et de modèles plus complexes (XGBoost, TabTransformer).

4.2 Perspectives d'amélioration

Bien que les résultats soient encourageants, plusieurs pistes d'amélioration apparaissent. Une première perspective consiste à enrichir l'espace des variables en intégrant des indicateurs macroéconomiques (taux d'intérêt, inflation, prix de l'énergie). De tels facteurs permettraient d'accroître la robustesse du modèle face à des crises systémiques telles que la pandémie de COVID-19 ou les chocs énergétiques récents.

Une deuxième piste concerne l'adoption de modèles spécifiquement conçus pour les séries temporelles, comme les réseaux LSTM, GRU ou le *Temporal Fusion Transformer*. Ces architectures pourraient mieux exploiter la dimension dynamique et capter les trajectoires financières pluriannuelles qui précèdent une faillite.

Enfin, l'amélioration de l'interprétabilité demeure un enjeu clé. L'utilisation de techniques comme les valeurs SHAP ou les mécanismes d'attention offre la possibilité de rendre transparents les résultats des modèles complexes, en identifiant les variables et interactions qui ont le plus contribué à la prédiction. Cette démarche renforcerait la confiance des régulateurs et des acteurs financiers dans l'utilisation de tels modèles pour la gestion proactive du risque.

4.3 Contributions et enseignements principaux

Cette étude apporte plusieurs contributions majeures au champ de la prédiction de défaillance :

- la construction d'un jeu de données réel, équilibré et couvrant dix années d'historique pour un large échantillon de PME françaises ;
- la comparaison systématique de trois familles de modèles — régression logistique, XGBoost et TabTransformer — afin de situer les performances de cette nouvelle architecture dans un cadre empirique rigoureux ;
- la mise en évidence du rôle critique de la profondeur historique et du prétraitement des données (imputation, normalisation, équilibrage) dans la réussite de la tâche prédictive ;

- la proposition d'une méthodologie reproductible applicable dans le cadre opérationnel des institutions financières et publiques.

Les résultats démontrent que, si la régression logistique conserve sa pertinence grâce à son haut niveau d'interprétabilité et sa compatibilité avec les pratiques bancaires, XGBoost constitue une référence robuste dans la littérature pour sa capacité à gérer l'hétérogénéité des données et le déséquilibre des classes. Quant au TabTransformer, il offre un gain significatif de performance, ouvrant la voie à l'introduction de modèles issus de la famille des Transformers dans la prédiction de la défaillance d'entreprises.

4.4 Limites et recommandations pour de futures recherches

Plusieurs limites doivent être reconnues. Premièrement, les résultats sont spécifiques au contexte français des PME, et leur généralisation à d'autres pays ou à de grandes entreprises doit être confirmée. Deuxièmement, la définition de la faillite adoptée dans ce travail (statut juridique et variables comptables) peut différer de celle utilisée dans d'autres études, influençant ainsi les comparaisons internationales. Troisièmement, la nature encore expérimentale de l'architecture TabTransformer pour ce type de données appelle à la prudence dans l'interprétation des résultats : des tests sur des échantillons plus vastes et plus hétérogènes sont nécessaires.

Pour les recherches futures, il est recommandé :

1. d'élargir le jeu de variables en incluant toutes les informations comptables et extra-comptables disponibles, afin de tirer parti de la capacité des algorithmes de *machine learning* à sélectionner automatiquement les variables pertinentes ;
2. de tester la robustesse du modèle dans différents contextes géographiques et sectoriels ;
3. d'approfondir l'évaluation comparative avec d'autres architectures modernes (par exemple CatBoost, LightGBM, ou modèles hybrides combinant statistiques et apprentissage profond) ;
4. d'analyser les performances en conditions de *real-time monitoring*, où l'actualisation continue des données pourrait être exploitée.

4.5 Conclusion générale

En définitive, cette recherche confirme que les méthodes d'apprentissage automatique et profond offrent un potentiel élevé pour la prédiction de la défaillance d'entreprises, mais que leur efficacité dépend étroitement du contexte, de la définition adoptée de la faillite et de la qualité des données sous-jacentes. La régression logistique reste un outil indispensable pour sa transparence, XGBoost se distingue comme une référence robuste, et le TabTransformer introduit une nouvelle génération de modèles exploitant les capacités du Transformer dans le domaine tabulaire.

Étant donné l'importance sociale et économique des faillites d'entreprises, l'amélioration continue des outils de prédiction constitue un enjeu crucial pour les chercheurs, les institutions financières et les décideurs publics. Les résultats de ce travail montrent que, sous certaines conditions, les approches basées sur les Transformers peuvent contribuer à enrichir les dispositifs de prévention et de gestion des risques, tout en ouvrant de nouvelles perspectives pour la recherche académique et l'innovation en finance.

Bibliography

- Aljawazneh, H., Mora, A. M., García-Sánchez, P., & Castillo-Valdivieso, P. A. (2021). Comparing the performance of deep learning methods to predict companies' financial failure. *IEEE Access*, 9, 97010–97038.
<https://doi.org/10.1109/ACCESS.2021.3093461>
- Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *Journal of Finance*, 23(4), 589–609.
<https://doi.org/10.2307/2978933>
- Altman, E. I. (2000). Predicting financial distress of companies: Revisiting the Z-score and ZETA® models. Working Paper, New York University.
<https://doi.org/10.4337/9780857936080.00027>
- Altman, E. I., Haldeman, R. G., & Narayanan, P. (1977). ZETA™ analysis: A new model to identify bankruptcy risk of corporations. *Journal of Banking & Finance*, 1(1), 29–54. [https://doi.org/10.1016/0378-4266\(77\)90017-6](https://doi.org/10.1016/0378-4266(77)90017-6)
- Altman, E. I., Iwanicz-Drozdzowska, M., Laitinen, E. K., & Suvas, A. (2015). Financial and non-financial variables as long-horizon predictors of bankruptcy. *SSRN Electronic Journal*. <https://doi.org/10.2139/ssrn.2669668>
- Altman, E. I., Iwanicz-Drozdzowska, M., Laitinen, E. K., & Suvas, A. (2017). Financial distress prediction in an international context: A review and empirical analysis of Altman's Z-score model. *Journal of International Financial Management & Accounting*, 28(2), 131–171. <https://doi.org/10.1111/jifm.12053>
- Altman, E. I., & McGough, T. P. (1974). Evaluation of a company as a going concern. *Journal of Accountancy*, 138(6), 50–57.
- Argenti, J. (1976). *Corporate Collapse: The Causes and Symptoms*. McGraw-Hill.
- Balcaen, S., & Ooghe, H. (2006). 35 years of studies on business failure: An overview of the classic statistical methodologies and their related problems. *The British Accounting Review*, 38(1), 63–93. <https://doi.org/10.1016/j.bar.2005.09.001>
- Barboza, F., Kimura, H., & Altman, E. I. (2017). Machine learning models and bankruptcy prediction. *Expert Systems with Applications*, 83, 405–417.
<https://doi.org/10.1016/j.eswa.2017.04.006>
- Batini, C., & Scannapieco, M. (2006). *Data Quality: Concepts, Methodologies and Techniques*. Springer.
- Beaver, W. H. (1966). Financial ratios as predictors of failure. *Journal of Accounting Research*, 4, 71–111. <https://doi.org/10.2307/2490171>

- Beaver, W. H. (1968). Market prices, financial ratios, and the prediction of failure. *Journal of Accounting Research*, 6(2), 179–192. <https://doi.org/10.2307/2490233>
- Bragoli, D., Ferretti, C., Ganugi, P., Marseguerra, G., Mezzogori, D., & Zammori, F. (2021). Machine-learning models for bankruptcy prediction: Do industrial variables matter? *Spatial Economic Analysis*, 17(2), 156–177. <https://doi.org/10.1080/17421772.2021.1977377>
- Brown, I., & Mues, C. (2012). An experimental comparison of classification algorithms for imbalanced credit scoring data sets. *Expert Systems with Applications*, 39(3), 3446–3453. <https://doi.org/10.1016/j.eswa.2011.09.033>
- Business Week*. (1980). Why companies fail. June issue.
- Carpenter, J. R., & Kenward, M. G. (2013). *Multiple Imputation and its Application*. Chichester, UK: John Wiley & Sons. <https://doi.org/10.1002/9781119942283>
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>
- Chen, T., & Guestrin, C. (2016, August). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). <https://doi.org/10.1145/2939672.2939785>
- Cheng-Ying, W. (2004). Using non-financial information to predict bankruptcy: A study of public companies in Taiwan. *International Journal of Management*, 21(2), 194. <https://www.proquest.com/openview/ef182e178652e4263d5d3fb9fe102f10/1?pq-origsite=gscholar&cbl=5703>
- Daily, C. M., & Dalton, D. R. (1994). Bankruptcy and corporate governance: The impact of board composition and structure. *Academy of Management Journal*, 37(6), 1603–1617. <https://doi.org/10.5465/256801>
- Dechow, P. M., Sloan, R. G., & Sweeney, A. P. (1995). Detecting earnings management. *The Accounting Review*, 70(2), 193–225 <https://www.jstor.org/stable/248303>.
- Fantazzini, D., & Figini, S. (2009). Random survival forests models for SME credit risk measurement. *Methodology and Computing in Applied Probability*, 11(1), 29–45. <https://doi.org/10.1007/s11009-008-9078-2>
- Freund, Y., & Schapire, R. E. (1997). A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of Computer and System Sciences*, 55(1), 119–139. <https://doi.org/10.1006/jcss.1997.1504>
- Gentry, J. A., Newbold, P., & Whitford, D. T. (1985). Classifying bankrupt firms with

- funds flow components. *Journal of Accounting Research*, 23(1), 146–160.
<https://doi.org/10.2307/2490911>
- Geiger, M. A., & Raghunandan, K. (2002). Auditor reporting on going-concern uncertainties: A research synthesis. *Auditing: A Journal of Practice & Theory*, 21(1), 173–196. <https://doi.org/10.2308/ajpt-50324>
- Gu, Q., Zhu, L., & Cai, Z. (2009). Evaluation measures of the classification performance of imbalanced data sets. In *Proceedings of the International Symposium on Intelligent Computing Applications* (pp. 461–471). Springer
https://doi.org/10.1007/978-3-642-04962-0_53.
- He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284.
<https://doi.org/10.1109/TKDE.2008.239>
- Huang, X., Khetan, A., Cvitkovic, M., & Karnin, Z. (2020). TabTransformer: Tabular data modeling using contextual embeddings. *arXiv preprint arXiv:2012.06678*.
<https://doi.org/10.48550/arXiv.2012.06678>
- Jones, J. J. (1991). Earnings management during import relief investigations. *Journal of Accounting Research*, 29(2), 193–228. <https://doi.org/10.2307/2491047>
- Jones, S. (2023). *Distress Risk and Corporate Failure Modelling: The State of the Art*. Routledge. <https://doi.org/10.4324/9781003187560>
- Jones, S., Johnstone, D., & Wilson, R. (2015). An empirical evaluation of the performance of binary classifiers in the prediction of credit ratings changes. *Journal of Banking & Finance*, 56, 72–85.
<https://doi.org/10.1016/j.jbankfin.2015.02.006>
- Jones, S., Johnstone, D., & Wilson, R. (2017). Predicting corporate bankruptcy: An evaluation of alternative statistical frameworks. *Journal of Business Finance & Accounting*, 44(1–2), 3–34. <https://doi.org/10.1111/jbfa.12218>
- Kanapickienė, R., Kanapickas, T., & Nečiūnas, A. (2023). Bankruptcy prediction for micro and small enterprises using financial, non-financial, business sector and macroeconomic variables: The case of the Lithuanian construction sector. *Risks*, 11(5), 97. <https://doi.org/10.3390/risks11050097>
- Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), 1–21.
- Khandani, A. E., Kim, A. J., & Lo, A. W. (2010). Consumer credit-risk models via machine-learning algorithms. *Journal of Banking & Finance*, 34(11), 2767–2787.

- <https://doi.org/10.1016/j.jbankfin.2010.06.001>
- Khosravi, A., Rezaee, Z., & Shajari, M. (2021). A deep learning model for bankruptcy prediction. *International Journal of Finance & Economics*.
<https://doi.org/10.1002/ijfe.2483>
- Laitinen, E. K. (1991). Financial ratios and different failure processes. *Journal of Business Finance & Accounting*, 18(5), 649–673.
<https://doi.org/10.1111/j.1468-5957.1991.tb00231.x>
- Laitinen, E. K. (1992). Prediction of failure of a newly founded firm. *Journal of Business Venturing*, 7(4), 323–340. [https://doi.org/10.1016/0883-9026\(92\)90005-C](https://doi.org/10.1016/0883-9026(92)90005-C)
- Lepot, M., Aubin, J.-B., & Clemens, F. H. L. R. (2017). Interpolation in time series: An introductive overview of existing methods, their performance criteria and uncertainty assessment. *Water*, 9(10), 796. <https://doi.org/10.3390/w9100796>
- Linnenluecke, M. K., Smith, T., & McKnight, B. (2020). Environmental, social and governance (ESG) performance in the context of industry peer effects: A multilevel analysis. *Business Strategy and the Environment*, 29(8), 3055–3070.
<https://doi.org/10.1002/bse.2586>
- Little, R. J. A., & Rubin, D. B. (2002). *Statistical Analysis with Missing Data* (2nd ed.). Wiley-Interscience. DOI indisponible [https://books.google.fr/books?hl=fr&lr=&id=BemMDwAAQBAJ&oi=fnd&pg=PR11&dq=Statistical+Analysis+with+Missing+Data%7D+\(2nd+ed.\).&ots=FCDU5WJXVW&sig=DsfCnFx06YCRpy0Egpv0Gf3CYuY&redir_esc=y#v=onepage&q=Statistical%20Analysis%20with%20Missing%20Data%7D%20\(2nd%20ed.\).&f=false](https://books.google.fr/books?hl=fr&lr=&id=BemMDwAAQBAJ&oi=fnd&pg=PR11&dq=Statistical+Analysis+with+Missing+Data%7D+(2nd+ed.).&ots=FCDU5WJXVW&sig=DsfCnFx06YCRpy0Egpv0Gf3CYuY&redir_esc=y#v=onepage&q=Statistical%20Analysis%20with%20Missing%20Data%7D%20(2nd%20ed.).&f=false) Little, R. J. A., & Rubin, D. B. (2019). *Statistical Analysis with Missing Data* (3rd ed.). Hoboken, NJ: John Wiley & Sons. <https://doi.org/10.1002/9781119482260>
- Mellahi, K., & Wilkinson, A. (2004). Organizational failure: A critique of recent research and a proposed integrative framework. *International Journal of Management Reviews*, 5–6(1), 21–41. <https://doi.org/10.1111/j.1460-8545.2004.00095.x>
- Ohlson, J. A. (1980). Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 18(1), 109–131.
<https://doi.org/10.2307/2490395>
- Platt, H. D., & Platt, M. B. (1990). Development of a class of stable predictive variables: The case of bankruptcy prediction. *Journal of Business Finance & Accounting*, 17(1), 31–51. <https://doi.org/10.1111/j.1468-5957.1990.tb00548.x>
- Platt, H. D., & Platt, M. B. (2012). Corporate board attributes and bankruptcy. *Journal of Business Research*, 65(8), 1139–1143.

- <https://doi.org/10.1016/j.jbusres.2011.08.003>
- Powers, D. M. W. (2011). Evaluation: From precision, recall and F-measure to ROC, informedness, markedness & correlation. *Journal of Machine Learning Technologies*, 2(1), 37–63.
- Rahm, E., & Do, H. H. (2000). Data cleaning: Problems and current approaches. *IEEE Data Engineering Bulletin*, 23(4), 3–13.
- Rijsbergen, C. J. van. (1979). *Information Retrieval* (2nd ed.). London: Butterworths.
- Schafer, J. L., & Graham, J. W. (2002). Missing data: Our view of the state of the art. *Psychological Methods*, 7(2), 147–177.
- Schapire, R. E., Freund, Y., Bartlett, P., & Lee, W. S. (1997). Boosting the margin: A new explanation for the effectiveness of voting methods. In *Proceedings of the Fourteenth International Conference on Machine Learning* (pp. 322–330).
- Schapire, R. E., & Singer, Y. (1999). Improved boosting algorithms using confidence-rated predictions. *Machine Learning*, 37(3), 297–336.
- <https://doi.org/10.1023/A:1007614523901>
- Shin, K. S., Lee, T. S., & Kim, H. J. (2005). An application of support vector machines in bankruptcy prediction model. *Expert Systems with Applications*, 28(1), 127–135.
- <https://doi.org/10.1016/j.eswa.2004.08.009>
- Stojanović, M., Apostolović, M., Stojanović, D., Milošević, Z., Toplaović, A., Mitić-Lakušić, V., & Golubović, M. (2014). Understanding sensitivity, specificity and predictive values. *Vojnosanitetski Pregled*, 71(11), 1062–1065.
- Suchier, S. (2006). *Apprentissage ensembliste et sélection de variables*. Thèse de doctorat, Université Paris 11.
- Tsai, C.-F., & Wu, J.-W. (2008). Using neural network ensembles for bankruptcy prediction and credit scoring. *Expert Systems with Applications*, 34(4), 2639–2649.
- <https://doi.org/10.1016/j.eswa.2007.05.019>
- Wagner, J. (2012). International trade and firm performance: A survey of empirical studies since 2006. *Review of World Economics*, 148(2), 235–267.
- <https://doi.org/10.1007/s10290-011-0116-8>
- Zhang, G., Hu, M. Y., Patuwo, B. E., & Indro, D. C. (1999). Artificial neural networks in bankruptcy prediction: General framework and cross-validation analysis. *European Journal of Operational Research*, 116(1), 16–32.
- [https://doi.org/10.1016/S0377-2217\(98\)00171-4](https://doi.org/10.1016/S0377-2217(98)00171-4)
- Zhou, Z.-H., Liu, X.-Y., & Tang, W. (2021). Cost-sensitive learning and its applications. *International Journal of Data Science and Analytics*, 11(1), 1–17.

<https://doi.org/10.1007/s41060-020-00233-2>

- Zieba, M., Tomczak, S. K., & Tomczak, J. M. (2016). Ensemble boosted trees with synthetic features generation in application to bankruptcy prediction. *Expert Systems with Applications*, 58, 93–101. <https://doi.org/10.1016/j.eswa.2016.03.001>
- Zmijewski, M. E. (1984). Methodological issues related to the estimation of financial distress prediction models. *Journal of Accounting Research*, 22(Supplement), 59–82. <https://doi.org/10.2307/2490859>
- Abedin, M. Z., Guotai, C., Hajek, P., & Zhang, T. (2023). Combining weighted SMOTE with ensemble learning for the class-imbalanced prediction of small business credit risk. *Complex & Intelligent Systems*, 9(4), 3559–3579. <https://doi.org/10.1007/s40747-021-00614-4>
- Aljawazneh, H., Mora, A. M., García-Sánchez, P., & Castillo-Valdivieso, P. A. (2021). Comparing the performance of deep learning methods to predict companies’ financial failure. *IEEE Access*, 9, 97010–97038. <https://doi.org/10.1109/ACCESS.2021.3093461>
- Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *Journal of Finance*, 23(4), 589–609. <https://doi.org/10.2307/2978933>
- Altman, E. I., Haldeman, R. G., & Narayanan, P. (1977). ZETA™ analysis: A new model to identify bankruptcy risk of corporations. *Journal of Banking & Finance*, 1(1), 29–54. [https://doi.org/10.1016/0378-4266\(77\)90017-6](https://doi.org/10.1016/0378-4266(77)90017-6)
- Altman, E. I., Iwanicz-Drozdowska, M., Laitinen, E. K., & Suvas, A. (2017). Financial distress prediction in an international context: A review and empirical analysis of Altman’s Z-score model. *Journal of International Financial Management & Accounting*, 28(2), 131–171. <https://doi.org/10.1111/jifm.12053>
- Chen, D., Ye, J., & Ye, W. (2023). Interpretable selective learning in credit risk. *Research in International Business and Finance*, 65, 101940. <https://doi.org/10.1016/j.ribaf.2023.101940>
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). <https://doi.org/10.1145/2939672.2939785>
- DeLong, E. R., DeLong, D. M., & Clarke-Pearson, D. L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach. *Biometrics*, 44(3), 837–845.

- <https://doi.org/10.2307/2531595>
- Huang, X., Khetan, A., Cvitkovic, M., & Karnin, Z. (2020). TabTransformer: Tabular data modeling using contextual embeddings. *arXiv preprint arXiv:2012.06678*.
<https://doi.org/10.48550/arXiv.2012.06678>
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems (NeurIPS 2017)*, 30. <https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>
- Ohlson, J. A. (1980). Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 18(1), 109–131.
<https://doi.org/10.2307/2490395>
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems (NeurIPS 2018)*, 31.
<https://proceedings.neurips.cc/paper/2018/hash/14491b756b3a51daac41c24863285549-Abstract.html>
- Somepalli, G., Schmidt, L., Goldblum, M., & Wilson, A. G. (2021). Saint: Improved neural networks for tabular data via row attention and contrastive pre-training. In *Advances in Neural Information Processing Systems (NeurIPS 2021)*, 34, 14335–14347. <https://doi.org/10.48550/arXiv.2106.01342>
- Charalambakis, E. C., & Garrett, I. (2019). On corporate financial distress prediction: What can we learn from private firms in a developing economy? *Review of Quantitative Finance and Accounting*, 52(2), 467–499.
<https://doi.org/10.1007/s11156-018-0706-2>
- Shumway, T. (2001). Forecasting bankruptcy more accurately: A simple hazard model. *The Journal of Business*, 74(1), 101–124. <https://doi.org/10.1086/209665>
- Yildirim, D., Bircan, H., & Yildirim, S. (2021). Explainable artificial intelligence approach for bankruptcy prediction: An application of Shapley additive explanations (SHAP). *Applied Soft Computing*, 111, 107708.
<https://doi.org/10.1016/j.asoc.2021.107708>